

Revisiting Fama–French Factors' Predictability with Bayesian Modelling and Copula-Based Portfolio Optimization

Y. Zhao, C. Stasinakis, G. Sermpinis, F. Da Silva Fernandes (2019)

Charlène JULIEN Elsa PAYA Loélia MEYER Arthur LE NET

Mai 2026

Plan

- 1 Introduction et données
- 2 Méthodologie de prévision
- 3 Modélisation de la dépendance dynamique
- 4 Optimisation de portefeuille
- 5 Performances des portefeuilles
- 6 Conclusion

Les facteurs de Fama–French sont des références centrales en gestion factorielle, mais leur prévision reste difficile : relations non linéaires, corrélations instables, séries fortement bruitées.

Zhao et al. (2019) proposent un cadre intégré combinant trois dimensions :

- **Prévision** : modèles linéaires, non linéaires, SVR, SC-SVR, DMA
- **Dépendance dynamique** : DCC, ADCC, GAS avec copule GH skewed- t
- **Optimisation** : portefeuilles Moyenne–Variance et Moyenne–CVaR

Prévision des facteurs → Dépendance dynamique → Optimisation de portefeuille

Source : Kenneth French Data Library — fréquence mensuelle, janvier 1965 – mars 2026

Cinq facteurs

- **MKT-RF** : rendement excédentaire du marché
- **SMB** : prime de taille
- **HML** : prime value
- **RMW** : prime de profitabilité
- **CMA** : prime d'investissement

Période	Début	Fin	Obs.
Total	Jan. 1965	Mars 2026	735
In-sample	Jan. 1965	Déc. 1999	420
Train	Jan. 1965	Déc. 1983	228
Test	Jan. 1984	Déc. 1999	192
OOS	Jan. 2000	Mars 2026	315

Construction du pool de prévisions

On construit un pool de **300 prédicteurs individuels** appliqués aux log-rendements mensuels des cinq facteurs sur la période in-sample (1965–1999).

- **Modèles linéaires (290)** : moyennes mobiles simples (SMA), exponentielles (EMA), modèles AR et ARMA
- **Modèles non linéaires (10)** : réseaux de neurones (MLP, RNN, HONN, PSN), ARBF-PSO, méthodes évolutionnaires (GP, GEP), modèles à régimes (LSTAR, ESTAR) et kNN

Ces 300 séries présentent une forte multicolinéarité. Une **ACP** est appliquée pour conserver 95% de la variance totale, ce qui réduit le pool à **17–22 composantes principales** par facteur.

Les deux méthodes prennent en entrée les composantes principales et produisent une prévision combinée par facteur. Elles diffèrent uniquement par leur calibration.

SVR (Vapnik, 1995) — hyperparamètres (C, ν) sélectionnés par *grid search* sur la période de test (1984–1999).

SC-SVR (Mirjalili, 2016) — remplace le *grid search* par l'algorithme Sine-Cosine, qui explore un espace continu et évite les optima locaux.

Dynamic Model Averaging (DMA)

Principe (Raftery et al., 2010) : le meilleur modèle peut changer au fil du temps. À chaque date t , le DMA produit une moyenne pondérée de $U = 2^{10} = 1024$ modèles candidats.

Mise à jour des coefficients — filtre de Kalman ($\lambda = 0.99$) :

$$\zeta_{t|t}^{(u)} = \zeta_{t|t-1}^{(u)} + K_t^{(u)} e_t^{(u)}$$

Mise à jour des poids — facteur d'oubli ($\delta = 0.99$) :

$$\omega_{t+1|t,u} \propto \omega_{t|t,u}^{\delta} \cdot p(y_t^* \mid M_u)$$

Pour chaque facteur i , on estime un AR(1)–GJR-GARCH(1,1,1) qui fournit les résidus standardisés $z_{i,t} = \varepsilon_{i,t} / \sigma_{i,t}$.

- **DCC / ADCC** : estimés directement sur $z_{i,t}$ (cadre gaussien)
- **GAS** : utilise les pseudo-uniformes $u_{i,t} = F_i(z_{i,t})$ obtenus par transformation PIT, dans un cadre copule

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$$

DCC (Engle, 2002)

$$Q_t = (1 - \alpha - \beta) \bar{Q} + \alpha z_{t-1} z'_{t-1} + \beta Q_{t-1}$$

ADCC (Cappiello, Engle & Sheppard, 2006)

$$Q_t = (1 - \alpha - \beta) \bar{Q} + \alpha z_{t-1} z'_{t-1} + \beta Q_{t-1} + \underbrace{-\gamma \bar{N} + \gamma n_{t-1} n'_{t-1}}_{\text{terme asymétrique}}$$

$$\text{avec } n_t = z_t \odot 1_{\{z_t < 0\}} \quad \text{et} \quad \alpha + \beta + \gamma < 1$$

Copule GH skewed-t (Demarta & McNeil, 2005)

Extension asymétrique de la copule de Student : le paramètre ν contrôle l'épaisseur des queues, tandis que λ introduit de l'asymétrie.

Les paramètres $\theta = (\alpha, \beta, \nu, \lambda)$ sont estimés par MLE sur chaque fenêtre glissante. La cible $\bar{R}$ est fixée à la corrélation de Spearman, selon une logique de *variance targeting*.

Récurrance GAS (Salvatierra & Patton, 2015)

$$z_{t+1} = (1 - \alpha - \beta) \bar{z} + \alpha s_t^z + \beta z_t, \quad R_{t+1} = \tanh(z_{t+1})$$

où $z_t = \operatorname{arctanh}(R_t)$ et s_t^z désigne le score de la log-densité de copule, scalé par l'information de Fisher ; la transformation $\tanh$ ramène les corrélations dans $(-1, 1)$.

Corrélations dynamiques moyennes OOS 2000–2017 vs Zhao et al. (Table 1)

	MKT-SMB	MKT-HML	MKT-RMW	MKT-CMA	SMB-HML	SMB-RMW	SMB-CMA	HML-RMW	HML-CMA	RMW-CMA
DCC	0.290	−0.100	−0.477	−0.174	0.033	−0.364	0.008	0.150	0.504	0.106
ADCC	0.289	−0.101	−0.477	−0.175	0.032	−0.365	0.006	0.150	0.504	0.107
<i>Réf. linéaire</i>	<i>0.253</i>	<i>−0.057</i>	<i>−0.505</i>	<i>−0.238</i>	<i>−0.071</i>	<i>−0.525</i>	<i>0.039</i>	<i>0.424</i>	<i>0.616</i>	<i>0.278</i>
GAS	0.254	−0.060	−0.456	−0.128	0.065	−0.348	0.040	0.112	0.467	0.108
<i>Réf. rang</i>	<i>0.309</i>	<i>−0.018</i>	<i>−0.580</i>	<i>−0.089</i>	<i>0.103</i>	<i>−0.385</i>	<i>0.080</i>	<i>0.137</i>	<i>0.519</i>	<i>0.088</i>

Les signes sont correctement retrouvés pour le GAS (**10/10**) et pour DCC/ADCC (**9/10**), avec des ordres de grandeur proches des corrélations du papier.

Les principales relations économiques sont reproduites : $\text{MKT-RMW} < 0$, $\text{SMB-RMW} < 0$, $\text{HML-CMA} > 0$.

L'objectif est d'évaluer si l'amélioration des prévisions des facteurs Fama–French se traduit en meilleures allocations de portefeuille.

Les auteurs comparent deux approches complémentaires :

- **Moyenne–Variance** : optimisation classique de Markowitz ;
- **Moyenne–CVaR** : optimisation du risque extrême avec copule skewed- t .

Deux types de portefeuilles sont étudiés :

- **Long-only** : sans vente à découvert ;
- **130/30** : exposition longue de 130% et courte de –30%.

Logique de la réplication : Les facteurs *MKT*, *SMB*, *HML*, *RMW* et *CMA* sont les actifs du portefeuille.

Les pondérations optimales sont obtenues en minimisant la variance du portefeuille pour un niveau donné de rendement espéré :

$$\min_{w_t} \sigma_{p,t}^2(w_t) = w_t^T \Sigma_t w_t \quad \text{sous les contraintes} \quad r_{p,t} = w_t^T r_{i,t} \quad \text{et} \quad w_t^T \mathbf{1} = 1.$$

où :

$$\Sigma_t = D_t R_t D_t \quad \text{avec} \quad D_t = \text{diag}(\sigma_{1,t}, \sigma_{2,t}, \dots, \sigma_{N,t})$$

Cette reconstruction est centrale : les prévisions RW, SC-SVR et DMA ne déterminent que la moyenne attendue μ_t , tandis que DCC, ADCC et GAS déterminent la structure de risque via Σ_t .

Modèle	Rendement annuel (%)	Sharpe	Sortino	MDD (%)	CDB
MKT	4.852	0.319	0.432	54.108	–
SMB	4.359	0.402	0.626	22.657	–
HML	4.176	0.383	0.602	28.318	–
RMW	5.223	0.483	0.591	23.266	–
CMA	4.186	0.601	1.352	14.675	–
1/N	4.559	0.937	1.419	15.084	0.935

Table – Panel A – Facteurs individuels et portefeuille équipondéré (1/N)

Optimisation moyenne–variance (sans vente à découvert)

Models	Annualized return (%)	Sharpe ratio	Sortino ratio	MDD (%)	CDB
RW Average	4.420	0.726	1.068	19.120	0.843
SC-SVR Average	5.062	0.580	0.811	29.924	0.414
DMA Average	3.124	0.568	0.875	18.685	0.963
Total Average	4.202	0.625	0.918	22.576	0.740
DCC Average	4.180	0.627	0.930	22.123	0.756
ADCC Average	4.181	0.627	0.929	22.171	0.755
GAS Average	4.246	0.620	0.894	23.435	0.710

Table – Panel B – Mean–Variance Optimization without Short-Selling

Optimisation moyenne–variance (portefeuilles 130/30)

Models	Annualized return (%)	Sharpe ratio	Sortino ratio	MDD (%)	CDB
RW Average	4.130	0.541	0.731	22.793	0.692
SC-SVR Average	4.375	0.518	0.678	27.438	-0.024
DMA Average	3.409	0.478	0.628	28.485	0.720
Total Average - S	3.971	0.512	0.679	26.239	0.463
DCC-S Average	3.825	0.501	0.661	25.804	0.456
ADCC-S Average	3.828	0.503	0.660	25.704	0.453
GAS-S Average	4.262	0.532	0.716	27.207	0.479

Table – Panel C – Mean–Variance Optimization with Short-Selling (130/30)

La variance ne tient compte que de la dispersion autour de la moyenne et elle peut attribuer un risque similaire à deux portefeuilles dont l'un est moins performant.

Le CVaR (Conditionnal Value at Risk) est moyenne pondérée des observations pour lesquelles la perte dépasse la VAR (extrémité gauche de la queue de distribution, left tail risk).

La Conditionnal Value at Risk peut s'écrire :

$$\text{CVaR}_\beta(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\beta(L)] \quad (1)$$

Principe de l'optimisation Moyenne-CVaR :

$$\text{Mean-CVaR} = (\mu_p, \text{CVaR}) \quad (2)$$

Nous utilisons les prévisions des rendements des facteurs obtenues à partir des modèles (RW, SC-SVR, DMA) qui constituent l'entrée de l'optimisation de portefeuille :

$$\mu_t = (\hat{r}_{MKT,t+1}, \hat{r}_{SMB,t+1}, \hat{r}_{HML,t+1}, \hat{r}_{RMW,t+1}, \hat{r}_{CMA,t+1})^\top \quad (3)$$

Processus :

- **Correction de l'autocorrélation** : moyenne conditionnelle avec un modèle autorégressif pour isoler la partie imprévisible du rendement $\varepsilon_{i,t}$;
- **Décomposition du résidu** : composante de volatilité variable dans le temps et une innovation standardisée.
- **Capture de l'hétéroscédasticité et effet de levier** : utilisation de GARCH.
- **Calcul du résidus standardisés** : ces résidus standardisés ne sont pas supposés normaux. On va alors modéliser chaque résidu standardisé avec une distribution skewed- t de Hansen.

$$z_{i,t} \sim F_{skt}(\eta_i, \lambda_i). \quad (4)$$

Plus η_i (nb ddl) est faible, plus les queues sont épaisses. Le paramètre λ_i mesure l'asymétrie de la distribution.

Par la suite, les auteurs utilisent une copule skewed-t pour modéliser la dépendance entre les facteurs (corrélation et tendance extrêmes similaires).

La fonction de répartition de cette copule s'écrit :

$$C_{skt}(u_{1,t}, \dots, u_{n,t}; \Sigma, \lambda, \nu) = F_{skt}(F_1^{-1}(u_{1,t}), \dots, F_n^{-1}(u_{n,t})). \quad (5)$$

Pour chaque simulation de Monte Carlo s . Après plusieurs milliers de simulations, on obtient une approximation de la distribution future du portefeuille :

$$R_p^{(1)}, R_p^{(2)}, \dots, R_p^{(N)} \quad (6)$$

La Conditional Value-at-Risk est calculée par la formulation de Rockafellar et Uryasev suivante :

$$\min_{(\mathbf{w}_t, \alpha)} F_\alpha(\mathbf{w}_t, \beta) = \alpha + \frac{1}{q(1-\beta)} \sum_{m=1}^q [-\mathbf{w}_t^\top \mathbf{r}_{m,t} - \alpha]^+ . \quad (7)$$

sous les contraintes suivantes :

$$\mu(\mathbf{w}_t) = -\mathbf{w}_t^\top \mathbf{r}_t \leq -R \quad (8)$$

et

$$\mathbf{w}_t^\top \mathbf{1} = 1. \quad (9)$$

Résultats : Mean–95% CVaR

Modèle	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
RW-DCC-SKT	3.357	0.760	0.660	20.297	0.631
RW-ADCC-SKT	4.214	1.002	0.829	19.166	0.703
RW-GAS-SKT	3.702	0.873	0.744	21.280	0.688
Average	3.758	0.878	0.744	20.248	0.674
SC-SVR-DCC-SKT	3.631	0.523	0.465	33.564	-10.541
SC-SVR-ADCC-SKT	3.654	0.529	0.467	34.804	-8.846
SC-SVR-GAS-SKT	3.664	0.493	0.440	39.392	—
Average	3.650	0.515	0.457	35.920	-9.694
DMA-DCC-SKT	2.262	0.528	0.478	17.877	0.827
DMA-ADCC-SKT	2.428	0.559	0.504	17.811	0.820
DMA-GAS-SKT	2.570	0.606	0.544	17.789	0.822
Average	2.420	0.564	0.509	17.826	0.823
Total Average	3.276	0.653	0.570	24.665	-1.862
DCC Average	3.083	0.604	0.534	23.913	-3.028
ADCC Average	3.432	0.697	0.600	23.927	-2.441
GAS Average	3.312	0.657	0.576	26.154	0.755

Résultats : optimisation Mean-95% CVaR

Modèle	Rend.	Ret/CVaR	Sortino	MDD	CDB
Sans vente à découvert					
RW avg.	3.758	0.878	0.744	20.248	0.674
SC-SVR avg.	3.650	0.515	0.457	35.920	-9.694
DMA avg.	2.420	0.564	0.509	17.826	0.823
Avec vente à découvert					
RW-S avg.	4.148	0.752	0.660	23.603	0.534
SC-SVR-S avg.	3.634	0.577	0.477	26.452	-2.958
DMA-S avg.	3.167	0.612	0.544	27.354	0.800

Messages clés

- RW domine en rendement et en Return/CVaR.
- DMA a un profil plus défensif sans short-selling.
- SC-SVR performe moins bien, surtout en MDD.
- La vente à découvert améliore légèrement les rendements.

Lien avec le papier

- Contrairement à Zhao et al., DMA ne domine pas.
- GAS reste compétitif mais pas systématiquement supérieur.

Zhao et al. (2019) montrent que des prévisions sophistiquées combinées à une modélisation fine de la dépendance améliorent significativement les performances de portefeuille.

Notre réplique valide les grandes conclusions du papier :

- DMA surpasse significativement le RW sur 4/5 facteurs et GAS reproduit fidèlement la structure de dépendance (10/10 signes, corrélation de 0.993 avec le panel de référence)
- La vente à découvert améliore les performances, et les stratégies fondées sur DMA présentent les drawdowns les plus faibles, reflétant le profil défensif mis en avant dans le papier

Les divergences quantitatives s'expliquent par des choix d'implémentation rendus nécessaires par des ambiguïtés méthodologiques dans le papier original et par des contraintes computationnelles.

Merci pour votre attention !