

Université Paris Dauphine – PSL

Master 2 272 – Ingénierie Économique et Financière
Parcours Finance Quantitative

Revisiting Fama–French Factors’ Predictability with Bayesian Modelling and Copula-Based Portfolio Optimization

Auteurs

Yang Zhao
Charalampos Stasinakis
Georgios Sermpinis
Filipa Da Silva Fernandes

Réalisé par

Charlène JULIEN
Elsa PAYA
Loélia MEYER
Arthur LE NET

Mai 2026

Contents

1	Introduction	1
2	Données et statistiques descriptives	1
2.1	Description des données	1
2.2	Description économique des facteurs	1
2.3	Construction des sous-périodes	2
3	Méthodologie de prévision	3
3.1	Modèles individuels linéaires	3
3.2	Modèles individuels non linéaires	4
3.2.1	Réseaux de neurones	4
3.2.2	Réseau à fonctions de base radiale optimisé par essaim particulière	4
3.2.3	Méthodes évolutionnaires	5
3.2.4	Modèle à transition lisse autorégressif	5
3.2.5	Algorithme des plus proches voisins	5
3.3	Sélection par analyse en composantes principales	5
3.3.1	Procédure d'application	6
3.3.2	Écart par rapport aux résultats du papier	6
3.3.3	Identification du meilleur modèle individuel	6
3.3.4	Reconstruction de la Table 3 et projection hors échantillon	6
3.4	Modèles SVR et SC-SVR	7
3.4.1	Principe du vSVR	7
3.4.2	Projection hors échantillon	8
3.4.3	SVR : calibration par recherche sur grille	8
3.4.4	SC-SVR : calibration par algorithme Sine-Cosine	8
3.5	Dynamic Model Averaging (DMA)	9
3.5.1	Principe fondamental	9
3.5.2	Modèle espace-état	9
3.5.3	Filtre de Kalman	9
3.5.4	Mise à jour des poids des modèles	10
3.5.5	Prévision finale	10
4	Modélisation de la dépendance dynamique	10
4.1	Modèle DCC	11
4.2	Modèle ADCC	11
4.3	Modèle GAS avec copule GH skewed-t	12
4.3.1	Distribution GH skewed-t	12
4.3.2	Densité de copule	12
4.3.3	Score GAS et récurrence	12
4.4	Validation empirique	13

5	Optimisation de portefeuille	14
5.1	Optimisation Moyenne–Variance	14
5.2	Optimisation Moyenne–CVaR	17
6	Évaluation des prévisions	25
6.1	Métriques d’erreur	25
6.2	Tests statistiques	27
7	Performances des portefeuilles	30
7.1	Métriques de performance	30
7.2	Facteurs individuels et portefeuille 1/N (Tables 8 & 9, Panel A)	31
7.3	Stratégies Mean–95% CVaR avec et sans vente à découvert (Table 9, Panels B & C) . . .	32
7.4	Stratégies Mean–99% CVaR avec et sans vente à découvert (Table 9, Panels B & C) . . .	34
8	Conclusion	35

1 Introduction

La prévision des rendements des facteurs de risque constitue un enjeu central de la gestion quantitative et de l'allocation d'actifs. Depuis les travaux de Fama et French (1993, 2015), les facteurs de Fama–French sont devenus des références majeures pour expliquer les variations des rendements des actifs financiers. Toutefois, la prévision des rendements factoriels demeure difficile en raison du caractère fortement bruité des séries financières, de possibles relations non linéaires ainsi que de corrélations instables entre facteurs au cours du temps.

Dans ce contexte, Zhao et al. proposent un cadre méthodologique combinant trois dimensions complémentaires. Premièrement, les rendements futurs des facteurs sont prédits à l'aide d'approches de combinaison de prévisions, incluant notamment le *Dynamic Model Averaging* (DMA), approche bayésienne permettant d'adapter dynamiquement les poids attribués aux modèles de prévision. Deuxièmement, la dépendance entre facteurs est modélisée à l'aide de copules t asymétriques associées à des dynamiques de corrélation conditionnelle de type DCC, ADCC et GAS. Enfin, les prévisions obtenues sont intégrées dans des stratégies d'optimisation de portefeuille moyenne–variance et moyenne–CVaR.

Appliquée aux cinq facteurs de Fama–French sur la période 1965–2017, la méthodologie de Zhao et al. met en évidence une amélioration significative des performances hors-échantillon relativement aux approches traditionnelles, tant en termes de précision de prévision que de performance de portefeuille.

L'objectif de ce projet est de répliquer la méthodologie proposée par Zhao et al. sur les mêmes données avec une extension jusqu'en 2026, d'en reproduire les principaux résultats empiriques et d'évaluer la robustesse des conclusions du papier. Nous proposons également une extension intégrant le facteur Momentum (UMD) comme sixième facteur afin d'étudier l'impact d'un univers factoriel élargi sur les performances des stratégies considérées.

2 Données et statistiques descriptives

2.1 Description des données

Les données utilisées dans cette étude proviennent de la bibliothèque de Kenneth French, référence standard de la littérature académique sur les modèles factoriels. Les séries couvrent la période janvier 1965 – mars 2026 à fréquence mensuelle, conformément au cadre empirique retenu par le papier avec une extension aux données les plus récentes.

L'univers étudié est constitué des cinq facteurs du modèle de Fama–French à cinq facteurs. Ces facteurs représentent différentes sources systématiques de risque expliquant les rendements des actifs financiers. Les séries sont exprimées en rendements en pourcentage et converties en rendements décimaux.

2.2 Description économique des facteurs

Les cinq facteurs retenus correspondent à différentes primes de risque traditionnellement étudiées dans la littérature financière :

- **MKT** (*Market Excess Return*) : facteur de marché correspondant au rendement excédentaire du portefeuille de marché relativement au taux sans risque. Il représente le risque systématique global du marché actions ;

- **SMB** (*Small Minus Big*) : facteur de taille mesurant l'écart de rendement entre les petites et les grandes capitalisations. Il capture historiquement la prime associée aux entreprises de petite taille ;
- **HML** (*High Minus Low*) : facteur de valeur représentant l'écart de rendement entre les entreprises présentant un ratio valeur comptable / valeur de marché élevé et celles présentant un ratio faible ;
- **RMW** (*Robust Minus Weak*) : facteur de profitabilité opposant les entreprises à forte rentabilité opérationnelle aux entreprises moins profitables ;
- **CMA** (*Conservative Minus Aggressive*) : facteur d'investissement correspondant à l'écart de rendement entre les entreprises adoptant une politique d'investissement conservatrice et celles ayant une politique d'investissement agressive.

Ces facteurs présentent des dynamiques hétérogènes, potentiellement non linéaires et dépendantes du régime de marché. Leur faible rapport signal/bruit rend leur prévision particulièrement difficile, ce qui justifie le recours à des méthodes avancées de combinaison de prévisions et de modélisation dynamique de la dépendance.

2.3 Construction des sous-périodes

Conformément au papier original, l'échantillon total est subdivisé en plusieurs sous-périodes distinctes afin de séparer les phases d'estimation, de validation et d'évaluation hors-échantillon.

La période janvier 1965 – décembre 1999 constitue la période *in-sample* utilisée pour l'estimation et la calibration des modèles. Cette période est elle-même divisée en deux sous-échantillons :

- une période d'entraînement (*training set*) allant de janvier 1965 à décembre 1983 ;
- une période de validation (*test set*) allant de janvier 1984 à décembre 1999.

La période janvier 2000 – mars 2026 correspond à la période hors-échantillon (*out-of-sample*) utilisée pour évaluer les performances réelles des modèles de prévision et des stratégies de portefeuille.

Cette séparation stricte entre estimation et évaluation permet de limiter les risques de sur-apprentissage (*overfitting*) et d'obtenir une mesure plus réaliste des performances des modèles dans un cadre de gestion quantitative.

Table 1: Découpage des sous-périodes

Période	Début	Fin	Observations
Total	Jan. 1965	Mars 2026	735
In-sample	Jan. 1965	Déc. 1999	420
Entraînement	Jan. 1965	Déc. 1983	228
Test	Jan. 1984	Déc. 1999	192
Hors-échantillon	Jan. 2000	Mars 2026	315

3 Méthodologie de prévision

3.1 Modèles individuels linéaires

Conformément à Zhao et al. (2019), quatre familles de modèles linéaires sont construites, totalisant 290 prédicteurs individuels appliqués aux log-rendements mensuels des cinq facteurs de Fama-French sur la période in-sample (1965-1999). Afin d'éviter tout biais de regard vers l'avenir, chaque prévision pour la date t n'utilise que les rendements observés jusqu'en $t - 1$.

La première famille est celle des moyennes mobiles simples (SMA), dont la prévision est définie par :

$$\hat{R}_t = \frac{1}{q} \sum_{i=1}^q R_{t-i}, \quad q \in \{3, \dots, 30\} \quad (1)$$

ce qui génère 28 modèles. La deuxième famille, les moyennes mobiles exponentielles (EMA), pondère les observations passées de façon décroissante avec $\alpha = 2/(1 + q)$, produisant également 28 modèles. La troisième famille regroupe les modèles autorégressifs (AR) d'ordre $q \in \{1, \dots, 24\}$:

$$\hat{R}_t = \beta_0 + \sum_{i=1}^q \beta_i R_{t-i} \quad (2)$$

soit 24 modèles. Enfin, les modèles ARMA(p, q) étendent les AR par une composante de moyenne mobile sur les résidus :

$$\hat{R}_t = \phi_0 + \sum_{j=1}^p \phi_j R_{t-j} + \sum_{k=1}^q \omega_k a_{t-k} \quad (3)$$

avec $p \in \{1, \dots, 15\}$ et $q \in \{1, \dots, 14\}$, produisant $15 \times 14 = 210$ combinaisons. Les paramètres des modèles AR et ARMA sont estimés une unique fois sur la période d'entraînement (1965-1983) puis maintenus fixes, ce qui garantit l'absence de fuite d'information tout en limitant le coût computationnel. Cette décision s'écarte de la procédure idéale dite *expanding window*, dans laquelle les paramètres seraient réestimés à chaque nouvelle date en incorporant toutes les observations disponibles jusqu'en $t - 1$. Le papier original ne précise pas explicitement la méthode d'estimation retenue, mais une *expanding window* produirait des prévisions AR/ARMA progressivement plus corrélées entre elles, dans la mesure où les coefficients de ARMA(1, 2) et ARMA(1, 3) convergeraient vers des valeurs similaires au fil du temps, ce qui réduirait la dimensionnalité effective du pool de prévisions et permettrait à l'ACP d'atteindre 95% de variance expliquée avec seulement 6 à 9 composantes, conformément aux résultats du papier. Avec des paramètres fixes, les 290 séries de prévisions restent structurellement distinctes, et l'ACP nécessite 17 à 22 composantes pour atteindre le même seuil. L'*expanding window* a été envisagée mais abandonnée pour des raisons pratiques : avec 419 observations in-sample et 234 modèles AR/ARMA à estimer pour chaque facteur, le temps de calcul dépasse 16 heures par facteur sur le matériel disponible, rendant la procédure inexécutable dans le cadre de ce travail. Cette limitation aura un impact sur les résultats des étapes suivantes, notamment sur les performances comparées de SVR, SC-SVR et DMA, dans la mesure où ces méthodes reçoivent davantage de composantes PCA redondantes en entrée, ce qui dégrade leur capacité de généralisation.

3.2 Modèles individuels non linéaires

Conformément à Zhao et al. (2019), qui renvoient pour les détails d’implémentation à Sermpinis, Stasinakis et Hassanniakalager (2017), dix modèles non linéaires sont construits et appliqués aux log-rendements mensuels des cinq facteurs de Fama-French sur la période in-sample (1965-1999). Contrairement aux modèles linéaires qui exploitent directement la structure temporelle de la série, les modèles non linéaires nécessitent une matrice de features construite à partir de 6 lags $R_{t-1}, R_{t-2}, \dots, R_{t-6}$ comme inputs pour prédire R_t . Ce choix est cohérent avec la présence de AR(6) dans les inputs retenus par l’ACP (Table 3 de Zhao et al., 2019). Les modèles sont estimés sur la période d’entraînement (1965-1983) et leurs prévisions sont produites sur l’ensemble de la période in-sample, conformément à l’utilisation de prévisions individuelles in-sample décrite dans le papier. Avant chaque modèle, les features sont standardisées via un *StandardScaler* ajusté uniquement sur la période d’entraînement, de sorte qu’aucune information de la période de test ne contamine l’estimation.

3.2.1 Réseaux de neurones

Les quatre premiers modèles sont des réseaux de neurones dont les conventions d’implémentation sont tirées de la Table A.2 de Sermpinis et al. (2017) : initialisation des poids selon $\mathcal{N}(0, 1)$, apprentissage par descente de gradient stochastique avec momentum 0.9, et activation sigmoïde en couche cachée :

$$F(z) = \frac{1}{1 + e^{-z}} \quad (4)$$

La taille de la couche cachée est fixée à 5 neurones. Sermpinis et al. (2017) précisent que le nombre maximal d’itérations de rétropropagation est optimisé en maximisant une fonction de performance sur le jeu de test, en explorant entre 1 000 et 100 000 itérations. Cet esprit est reproduit via un arrêt anticipé (*early stopping*) : l’entraînement s’interrompt si la RMSE sur la période de test ne s’améliore pas pendant 100 epochs consécutifs, avec un maximum de 5 000 epochs. Une régularisation L2 ($\lambda = 10^{-3}$) est ajoutée pour limiter le surapprentissage.

Les quatre architectures se distinguent comme suit. Le **MLP** (*Multilayer Perceptron*) est le réseau feedforward standard, composé d’une couche cachée sigmoïde et d’une sortie linéaire. Le **RNN** est un réseau de type Elman (1990), cité explicitement par Sermpinis et al. (2017), dans lequel la couche cachée reçoit à la fois les features courantes et son propre état caché au pas précédent, lui conférant une mémoire à court terme. Le **HONN** (*Higher Order Neural Network*) enrichit les features avec des produits croisés d’ordre 2 entre les lags avant d’appliquer un MLP, ce qui lui permet de capturer des interactions non linéaires entre rendements passés sans ajouter de couches supplémentaires. Enfin, le **PSN** (*Psi-Sigma Network*), introduit par Ghosh et Shin (1991), se distingue par le fait que chaque neurone caché calcule le produit des activations sigmoïdes de ses entrées pondérées plutôt que leur somme. Conformément à la Table A.2 de Sermpinis et al. (2017), sa couche de sortie est également sigmoïde, ce qui en fait la seule architecture parmi les cinq dont la sortie n’est pas linéaire.

3.2.2 Réseau à fonctions de base radiale optimisé par essaim particulière

Le modèle **ARBF-PSO** est un réseau à fonctions de base radiale dont les neurones calculent une activation gaussienne :

$$\phi(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2\sigma^2}\right) \quad (5)$$

où $\mathbf{c}$ est un centre et σ une largeur. La sortie est une combinaison linéaire de ces activations, dont les poids sont estimés par moindres carrés une fois les centres fixés. Les paramètres $\mathbf{c}$ et σ sont optimisés par un algorithme d'essaim particulaire (PSO) simulant le comportement collectif de 20 particules sur 50 itérations, selon les hyperparamètres standards de Clerc et Kennedy (2002).

3.2.3 Méthodes évolutionnaires

Le **GP** (*Genetic Programming*) et le **GEP** (*Gene Expression Programming*) sont deux méthodes évolutionnaires qui cherchent des expressions mathématiques s'ajustant aux données en utilisant les opérateurs $\{+, -, \times, \div, \sqrt{\cdot}, \log\}$. Le GP représente les expressions sous forme d'arbres et les fait évoluer par croisement et mutation sur 10 générations et 500 individus. Le GEP, décrit par Ferreira (2001) et cité par Sermpinis et al. (2017), encode les expressions dans des chromosomes linéaires de longueur fixe, ce qui résout le problème de la taille variable des arbres du GP, avant de les évaluer via le langage Karva.

3.2.4 Modèle à transition lisse autorégressif

Le **STAR** (*Smooth Transition Autoregressive*) combine deux régimes autorégressifs par une fonction de transition douce $G(s)$. Sermpinis et al. (2017) distinguent deux variantes : le LSTAR, dont la fonction de transition est logistique :

$$G(s) = \frac{1}{1 + \exp(-\gamma(s - c))} \quad (6)$$

et l'ESTAR, dont la fonction de transition est exponentielle :

$$G(s) = 1 - \exp(-\gamma(s - c)^2) \quad (7)$$

Sermpinis et al. (2017) explorent les ordres 1 à 20 pour chacune des deux variantes. Dans le cadre de ce travail, une seule instance par type est retenue, dont l'ordre est sélectionné par minimisation de la RMSE sur la période de test parmi les ordres 1 à 5. Les paramètres sont estimés par l'algorithme de Nelder-Mead.

3.2.5 Algorithme des plus proches voisins

Le modèle **kNN** (*k-Nearest Neighbours*) identifie les k patterns historiques les plus proches du vecteur de lags courant selon la distance euclidienne et en calcule la moyenne pour produire une prévision. Sermpinis et al. (2017) précisent que le jeu de paramètres optimal est sélectionné selon la performance de trading in-sample. En l'absence d'accès à cette métrique, la valeur $k = 5$ est retenue sur la base de la RMSE minimale sur la période de test.

3.3 Sélection par analyse en composantes principales

Une fois les 290 prévisions individuelles linéaires et les 10 prévisions non linéaires obtenues, il est nécessaire de réduire la dimensionnalité de ce pool avant de l'utiliser comme entrée des méthodes de combinaison. En effet, passer directement ces 300 séries à un SVR ou un DMA poserait un problème de multicollinéarité sévère : SMA(3) et SMA(4) produisent des prévisions quasi-identiques, tout comme ARMA(1,2) et ARMA(1,3). Conformément à Zhao et al. (2019), une analyse en composantes principales (ACP) est appliquée afin d'éliminer les variables fortement corrélées tout en conservant 95% de la variance totale.

3.3.1 Procédure d'application

L'ACP est ajustée sur l'ensemble de la période in-sample TRAIN+TEST (1965-1999), soit 419 observations, ce qui garantit une structure de corrélation stable. La procédure se déroule en quatre étapes. Dans un premier temps, les colonnes contenant moins de 90% de valeurs valides sont supprimées, afin de traiter les valeurs manquantes des premiers mois des modèles à longue fenêtre, SMA(30) ne disposant pas de valeur pour les 30 premières observations. Dans un deuxième temps, les valeurs manquantes résiduelles sont imputées par la moyenne de chaque colonne. Dans un troisième temps, les prévisions sont standardisées à moyenne nulle et variance unitaire, ce qui est requis pour que toutes les colonnes contribuent équitablement à l'ACP indépendamment de leur échelle. Enfin, l'ACP est appliquée avec le paramètre $n_components=0.95$, qui retient automatiquement le nombre minimum de composantes expliquant 95% de la variance totale, conformément au seuil cité par Zhao et al. (2019).

3.3.2 Écart par rapport aux résultats du papier

Le papier rapporte 6 à 9 composantes principales par facteur, alors que notre implémentation en produit 17 à 22. Cet écart s'explique directement par la stratégie d'estimation des modèles AR et ARMA retenue dans ce travail. Avec des paramètres fixés une unique fois sur la période d'entraînement, ARMA(1,2) et ARMA(1,3) produisent des prévisions structurellement distinctes tout au long de la période in-sample. Dans le cadre d'une *expanding window*, ces deux modèles verraient les mêmes données croissantes et leurs coefficients convergeraient progressivement, rendant leurs prévisions très similaires et donc très corrélées. La redondance accrue du pool permettrait alors à l'ACP de trouver peu de directions distinctes et d'atteindre 95% de variance avec seulement 6 à 9 composantes. Avec des paramètres fixes, les 300 séries restent structurellement différentes et l'ACP nécessite davantage de composantes pour atteindre le même seuil. Il convient de noter que les inputs réels transmis à SVR, SC-SVR et DMA sont les composantes principales elles-mêmes, et non les noms des modèles affichés dans la Table 3 de Zhao et al. (2019).

3.3.3 Identification du meilleur modèle individuel

En parallèle de la réduction dimensionnelle, le meilleur prédicteur individuel est identifié parmi les 300 modèles par minimisation de la RMSE sur la période de test (1984-1999) :

$$RMSE = \sqrt{\frac{1}{T} \sum_{t=1}^T (\hat{R}_t - R_t)^2} \quad (8)$$

Ce modèle, mis en gras dans la Table 3 de Zhao et al. (2019), sert ensuite de benchmark dans les Tables 4 à 6 pour évaluer si les méthodes de combinaison apportent un gain réel par rapport au meilleur prédicteur individuel. Notre implémentation reproduit correctement le résultat du papier pour le facteur MKT, pour lequel PSN apparaît comme le modèle le plus performant.

3.3.4 Reconstruction de la Table 3 et projection hors échantillon

Le papier ne précise pas comment remonter des composantes principales aux noms des modèles originaux. La décision retenue consiste à identifier, pour chaque composante PC_k , le modèle dont le loading absolu est maximal car ça mesure la contribution d'un modèle à une composante et désignant donc son représentant naturel. Une déduplication est ensuite appliquée pour éviter qu'un même modèle apparaisse plusieurs fois.

Enfin, les objets ACP ajustés (le *StandardScaler* et l'objet ACP de scikit-learn) sont sérialisés et sauvegardés. Cela permet de projeter les prévisions individuelles hors échantillon (2000-2017) dans le même espace que les composantes in-sample en appliquant la même transformation sans la réajuster, ce qui évite tout biais de regard vers l'avenir lors des étapes suivantes.

Table 2: Best predictors' set

MKT	SMB	HML	RMW	CMA
PSN	GP	ARMA(2,2)	EMA(19)	ESTAR(1)
ARMA(7,11)	ARMA(15,3)	ARMA(4,6)	ARMA(5,12)	ARMA(11,2)
EMA(16)	EMA(19)	EMA(21)	EMA(23)	EMA(30)
ARMA(2,6)	ARMA(5,1)	SMA(23)	ARMA(3,1)	ARMA(6,2)
ARMA(1,8)	ARMA(3,3)	ARMA(3,14)	ARMA(12,5)	ARMA(14,13)
ARMA(10,5)	ARMA(8,2)	ARMA(3,1)	ARMA(4,6)	ARMA(3,3)
ARMA(5,2)	ARMA(13,9)	ARMA(6,9)	ARMA(3,3)	ARMA(11,6)
ARMA(1,2)	SMA(3)	ARMA(13,4)	ARMA(3,10)	AR(19)
SMA(24)	ARMA(14,14)	ARMA(5,12)	ARMA(3,11)	ARMA(12,7)
ARMA(1,1)	ARMA(13,6)	ARMA(12,4)	ARMA(8,10)	ARMA(12,2)
ARMA(10,11)	ARMA(10,11)	ARMA(7,10)	ARMA(7,3)	ARMA(14,10)
AR(2)	ARMA(14,7)	ARMA(14,9)	AR(21)	SMA(6)
ARMA(5,12)	ARMA(1,10)	ARMA(7,12)	ARMA(14,6)	ARMA(5,10)
RNN	ARMA(1,11)	ARMA(7,14)	ARMA(4,4)	ARMA(8,4)
ARMA(2,4)	ARMA(6,8)	ARMA(1,11)	HONN	ARMA(14,4)
ARMA(12,2)	PSN	GEP	ARMA(10,14)	PSN
ARBF-PSO	ARBF-PSO	PSN	PSN	ARMA(3,4)
	ARMA(9,6)	kNN	ARMA(12,10)	GEP
	HONN		GP	RNN
	GEP		ARMA(6,13)	

Le modèle en gras est le meilleur prédicteur individuel par facteur, sélectionné par RMSE minimale sur la période de test (1984-1999).

3.4 Modèles SVR et SC-SVR

Les méthodes SVR et SC-SVR constituent les deux premières techniques de combinaison de prévisions. Toutes deux prennent en entrée les composantes principales issues de l'ACP, qui résument les 300 prévisions individuelles et produisent une unique prévision combinée par facteur sur la période hors échantillon (2000-2017). Elles se distinguent uniquement par leur procédure de calibration des hyperparamètres.

3.4.1 Principe du vSVR

Conformément à Zhao et al. (2019), la variante vSVR est utilisée. Le SVR cherche une fonction $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$ qui prédit le rendement à partir des composantes principales en minimisant simultanément la norme $\|\mathbf{w}\|^2$ et les erreurs de prévision. La variante ν -SVR remplace le paramètre ε par un paramètre $\nu \in (0, 1)$ qui contrôle à la fois la borne supérieure sur la fraction d'erreurs tolérées et la borne inférieure sur la fraction de vecteurs de support, ce qui rend la calibration plus intuitive. La transformation non linéaire des données est assurée par un noyau gaussien à base radiale :

$$K(\mathbf{x}_i, \mathbf{x}) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}\|^2\right) \quad (9)$$

qui projette implicitement les données dans un espace de grande dimension où une frontière linéaire est apprise, ce qui équivaut à une frontière non linéaire dans l'espace original.

3.4.2 Projection hors échantillon

Les composantes principales étant calculées uniquement sur la période in-sample (1965-1999), les prévisions individuelles de la période hors échantillon (2000-2017) doivent être projetées dans le même espace avant d'être transmises au SVR. Pour ce faire, le StandardScaler et l'objet ACP ajustés in-sample sont appliqués aux nouvelles observations sans être réajustés ce qui garantit l'absence de tout biais de regard vers l'avenir.

3.4.3 SVR : calibration par recherche sur grille

Zhao et al. (2019) indiquent que les paramètres C et ν sont calibrés par une recherche exhaustive sur grille (*grid search*). La combinaison optimale (C, ν) est sélectionnée par minimisation de la RMSE sur la période de test (1984-1999), avec $C \in \{0.001, 0.01, 0.1, 1, 10, 100, 1000\}$ et $\nu \in \{0.05, 0.10, \dots, 0.95\}$, soit 77 combinaisons testées. On observe que $C = 100$ est systématiquement sélectionné avec une RMSE très faible, ce qui traduit un phénomène de mémorisation des données de test. Cette limite s'explique par le ratio observations/features défavorable : avec 17 à 22 composantes pour 192 observations de test, le SVR ne peut apprendre de relation robuste. Dans le papier original ce ratio est plus favorable car seulement 6 à 9 composantes sont retenues grâce à l'*expanding window*.

3.4.4 SC-SVR : calibration par algorithme Sine-Cosine

Le SC-SVR remplace la recherche sur grille par l'algorithme Sine-Cosine (SC) de Mirjalili (2016) qui explore un espace continu sans grille prédéfinie. Zhao et al. (2019) justifient ce choix par la capacité du SC à générer des solutions plus diversifiées et à éviter les optima locaux. Une population de 30 solutions est initialisée aléatoirement dans l'espace (C, ν) puis mise à jour à chaque itération selon :

$$P_j^{(t+1)} = \begin{cases} P_j^{(t)} + r_1 \cdot \sin(r_2) \cdot |r_3 P_j^{**} - P_j^{(t)}| & \text{si } r_4 < 0.5 \\ P_j^{(t)} + r_1 \cdot \cos(r_2) \cdot |r_3 P_j^{**} - P_j^{(t)}| & \text{si } r_4 \geq 0.5 \end{cases} \quad (10)$$

où P_j^{**} est la meilleure solution courante, $r_2 \in [0, 2\pi]$ est un angle aléatoire, $r_3 \in [0, 2]$ est un poids aléatoire, et $r_4 \in [0, 1]$ détermine l'usage de la fonction sinus ou cosinus. Le paramètre $r_1 = c'' - t \cdot (c''/T'')$ décroît linéairement de 2 à 0 sur les 100 itérations favorisant l'exploration en début d'optimisation et l'exploitation en fin de processus. La fonction objectif à maximiser est celle définie par Zhao et al. (2019) :

$$\text{Fitness} = \frac{1}{1 + \text{RMSE}} \quad (11)$$

Les bornes de recherche $C \in [0.001, 1000]$ et $\nu \in [0.05, 0.95]$ sont identiques à celles du grid search. Cette approche produit des valeurs de C distinctes par facteur, reflétant la structure propre de chaque série, contrairement au grid search qui sélectionne systématiquement la valeur limite $C = 100$.

Une fois les hyperparamètres optimaux identifiés, le vSVR est entraîné sur la période de test (1984-1999) pour les deux méthodes et appliqué aux 211 composantes hors échantillon projetées produisant ainsi une série de prévisions mensuelles par facteur.

3.5 Dynamic Model Averaging (DMA)

Le Dynamic Model Averaging (DMA), proposé par Raftery, Kárný et Ettler (2010) et appliqué par Zhao et al. (2019) comme méthode principale de combinaison, est une implémentation récursive du moyennage bayésien de modèles qui permet de sélectionner différents sous-ensembles de variables explicatives au fil du temps avec des coefficients variables. Contrairement au SVR et au SC-SVR qui calibrent des paramètres fixes sur la période de test avant de prédire hors échantillon, le DMA apprend en continu : ses poids et coefficients s'actualisent à chaque nouvelle observation, y compris sur la période hors échantillon.

3.5.1 Principe fondamental

L'idée centrale du DMA est que le meilleur modèle de prévision peut changer au fil du temps. À chaque date t , plutôt que de sélectionner un unique modèle, le DMA maintient une distribution de probabilité sur l'ensemble des modèles candidats et produit une prévision comme moyenne pondérée de leurs prévisions individuelles. Les modèles ayant bien prévu récemment reçoivent un poids plus élevé tandis que les autres sont progressivement oubliés via un facteur d'oubli δ .

Chaque modèle candidat u correspond à un sous-ensemble des composantes principales utilisées comme inputs. Avec v^* composantes disponibles, on énumère tous les 2^{v^*} sous-ensembles possibles, chacun définissant un modèle distinct. Zhao et al. (2019) avertissent que le DMA devient impraticable lorsque v^* dépasse 20. Nos données produisant 17 à 22 composantes, v^* est limité aux 10 premières composantes, celles qui expliquent le plus de variance, ce qui donne $U = 2^{10} = 1024$ modèles candidats par facteur.

3.5.2 Modèle espace-état

Pour chaque modèle candidat u , le DMA repose sur deux équations. L'équation d'observation relie le rendement aux composantes sélectionnées :

$$y_t^* = F_t^{(u)'} \zeta_t^{(u)} + \varepsilon_t^{(u)} \quad (12)$$

où $F_t^{(u)}$ est le vecteur des composantes du sous-ensemble u à la date t et $\zeta_t^{(u)}$ est le vecteur de coefficients. L'équation d'état permet aux coefficients d'évoluer dans le temps :

$$\zeta_t^{(u)} = \zeta_{t-1}^{(u)} + \eta_t^{(u)} \quad (13)$$

Cette évolution est ce qui rend le DMA adaptatif, les coefficients n'étant pas fixes comme dans le SVR.

3.5.3 Filtre de Kalman

À chaque date t et pour chaque modèle u , les coefficients sont mis à jour par un filtre de Kalman. La variance des coefficients est d'abord propagée avec le facteur d'oubli λ :

$$C_{t|t-1}^{(u)} = \frac{1}{\lambda} C_{t-1|t-1}^{(u)} \quad (14)$$

Conformément à Zhao et al. (2019), $\lambda = 0.99$, ce qui signifie que la variance augmente légèrement à chaque pas et permet aux coefficients de dériver lentement. L'erreur de prévision est ensuite calculée :

$$e_t^{(u)} = y_t^* - F_t^{(u)'} \zeta_{t|t-1}^{(u)} \quad (15)$$

Le gain de Kalman $K_t^{(u)} = C_{t|t-1}^{(u)} F_t^{(u)} / f_t^{(u)}$ détermine dans quelle mesure cette erreur corrige les coefficients :

$$\zeta_{t|t}^{(u)} = \zeta_{t|t-1}^{(u)} + K_t^{(u)} e_t^{(u)} \quad (16)$$

La matrice de variance est mise à jour via la formule de Joseph pour garantir la stabilité numérique :

$$C_{t|t}^{(u)} = (I - K_t^{(u)} F_t^{(u)'}) C_{t|t-1}^{(u)} (I - K_t^{(u)} F_t^{(u)'})' + R \cdot K_t^{(u)} K_t^{(u)'} \quad (17)$$

3.5.4 Mise à jour des poids des modèles

La mise à jour des poids se déroule en deux étapes. La vraisemblance prédictive du modèle u , c'est-à-dire la probabilité qu'il aurait attribuée à la valeur observée, est d'abord calculée :

$$p(y_t^* | M_u) = \mathcal{N}(y_t^*; F_t^{(u)'} \zeta_{t|t-1}^{(u)}, f_t^{(u)}) \quad (18)$$

Les modèles ayant bien prévu y_t^* reçoivent une vraisemblance élevée et voient leurs poids augmenter. Le facteur d'oubli δ est ensuite appliqué conformément à Zhao et al. (2019) :

$$\omega_{t+1|t,u} = \frac{\omega_{t|t,u}^\delta}{\sum_{l=1}^U \omega_{t|t,l}^\delta} \quad (19)$$

avec $\delta = 0.99$. L'ensemble des calculs est effectué en logarithme pour garantir la stabilité numérique.

3.5.5 Prévision finale

À chaque date t , la prévision DMA est la moyenne pondérée des prévisions de tous les modèles candidats, pondérée par leurs poids avant observation :

$$\hat{y}_t = \sum_{u=1}^U \omega_{t|t-1,u} \cdot F_t^{(u)'} \zeta_{t|t-1}^{(u)} \quad (20)$$

Le modèle vide, qui prédit systématiquement zéro, est inclus parmi les $U = 1024$ candidats et peut recevoir un poids élevé lorsque les composantes principales n'ont pas de pouvoir prédictif à certaines périodes. Les poids initiaux sont égaux à $1/U$, les coefficients sont initialisés à $\zeta_0 = \mathbf{0}$ et la matrice de variance à $C_0 = I$, conformément à la convention standard de Raftery et al. (2010). La variance d'observation R est initialisée à la variance empirique des dix premières observations afin d'adapter l'échelle à chaque facteur.

4 Modélisation de la dépendance dynamique

L'objectif de cette étape est d'estimer la structure de dépendance dynamique entre les cinq facteurs de Fama–French : MKT-RF, SMB, HML, RMW et CMA. Trois modèles sont comparés : DCC, ADCC et GAS, par ordre de complexité croissante. Les deux premiers opèrent directement sur les résidus

standardisés dans un cadre gaussien ; le troisième adopte une approche par copule plus flexible, capable de capturer l'asymétrie et les queues épaisses des distributions marginales. Les trois modèles sont estimés sur une fenêtre roulante de 60 mois, conformément à Zhao et al. (2019).

Pour chaque facteur i et à chaque date t , la moyenne et la variance conditionnelles sont modélisées conjointement par un AR(1)–GJR–GARCH(1,1,1) :

$$\begin{aligned} r_{i,t} &= \mu_i + \varphi_i r_{i,t-1} + \varepsilon_{i,t}, \\ \sigma_{i,t}^2 &= \omega_i + \alpha_i \varepsilon_{i,t-1}^2 + \gamma_i \varepsilon_{i,t-1}^2 \mathbf{1}_{\{\varepsilon_{i,t-1} < 0\}} + \beta_i \sigma_{i,t-1}^2, \end{aligned}$$

où le terme γ_i capture l'effet de levier. Les résidus standardisés $z_{i,t} = \varepsilon_{i,t} / \sigma_{i,t}$ constituent l'entrée des modèles DCC et ADCC. Le modèle GAS repose quant à lui sur une approche par copule, utilisant les pseudo-uniformes obtenus par transformation PIT des résidus :

$$u_{i,t} = F_i(z_{i,t}) \in (0, 1).$$

4.1 Modèle DCC

Le modèle DCC (*Dynamic Conditional Correlation*) d'Engle (2002) décompose la matrice de variance-covariance conditionnelle H_t en :

$$H_t = D_t R_t D_t,$$

où D_t est la matrice diagonale des volatilités et R_t la matrice de corrélation dynamique, obtenue par normalisation d'une matrice de quasi-corrélation Q_t :

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}.$$

La matrice Q_t évolue selon la récurrence :

$$Q_t = (1 - \alpha - \beta) \bar{Q} + \alpha z_{t-1} z'_{t-1} + \beta Q_{t-1},$$

avec $\bar{Q}$ la corrélation inconditionnelle de la fenêtre, α la réactivité aux chocs récents, β la persistance des corrélations passées, et $\alpha + \beta < 1$ pour garantir la stationnarité. Les paramètres (α, β) sont estimés par maximum de vraisemblance, en maximisant la contribution de vraisemblance de la partie corrélation :

$$\ell_t = -\frac{1}{2} [\log |R_t| + z'_t R_t^{-1} z_t - z'_t z_t],$$

où le terme $z'_t z_t$ est soustrait afin d'isoler la contribution de la corrélation, les composantes univariées ayant déjà été prises en compte lors de l'estimation des modèles GARCH marginaux.

4.2 Modèle ADCC

Le modèle ADCC (*Asymmetric Dynamic Conditional Correlation*) de Cappiello, Engle et Sheppard (2006) étend le DCC en capturant l'asymétrie des corrélations face aux chocs négatifs, les marchés ayant tendance à se corréler davantage lors des baisses que lors des hausses. En notant $n_t = z_t \odot \mathbf{1}_{\{z_t < 0\}}$ la partie négative des innovations, la dynamique devient :

$$Q_t = (1 - \alpha - \beta) \bar{Q} - \gamma \bar{N} + \alpha z_{t-1} z'_{t-1} + \gamma n_{t-1} n'_{t-1} + \beta Q_{t-1},$$

où $\bar{N} = \mathbb{E}[n_t n'_t]$ est estimée empiriquement sur la fenêtre et $\gamma \geq 0$ mesure la réaction additionnelle aux chocs négatifs. La contrainte de stationnarité devient $\alpha + \beta + \gamma < 1$, et le modèle se réduit au DCC standard lorsque $\gamma = 0$.

4.3 Modèle GAS avec copule GH skewed-t

4.3.1 Distribution GH skewed-t

La copule repose sur la loi GH skewed-t de Demarta et McNeil (2005), qui généralise la loi de Student en introduisant un paramètre d'asymétrie. La densité univariée s'écrit :

$$f_1(x; \nu, \lambda) \propto K_{\frac{\nu+1}{2}}(|\lambda|\sqrt{x^2 + \nu}) \frac{e^{\lambda x}}{(x^2 + \nu)^{(\nu+1)/4}},$$

où $\nu > 2$ contrôle l'épaisseur des queues, λ l'asymétrie, et K_ν désigne la fonction de Bessel modifiée de seconde espèce. Lorsque $\lambda = 0$, on retrouve la loi de Student standard.

La densité multivariée de dimension N , paramétrée par la matrice de corrélation R_t , est :

$$f_N(x; R_t, \nu, \lambda) \propto K_{\frac{\nu+N}{2}}(\sqrt{\psi_N(q_N + \nu)}) \frac{e^{\lambda \mathbf{1}' R_t^{-1} x}}{(q_N + \nu)^{(\nu+N)/4}},$$

où $q_N = x' R_t^{-1} x$ est la distance de Mahalanobis au carré et $\psi_N = \lambda^2 (\mathbf{1}' R_t^{-1} \mathbf{1})$ capte la contribution de l'asymétrie à la structure de dépendance.

4.3.2 Densité de copule

Les pseudo-uniformes $u_{i,t}$ sont transformés en quantiles de la loi GH skewed-t par inversion numérique de la CDF, $x_{i,t} = F^{-1}(u_{i,t}; \nu, \lambda)$. La log-densité de copule s'écrit alors :

$$\log c(u_t; R_t, \nu, \lambda) = \log f_N(x_t; R_t, \nu, \lambda) - \sum_{i=1}^N \log f_1(x_{i,t}; \nu, \lambda),$$

où la différence entre densité jointe et densités marginales isole la structure de dépendance entre les facteurs, indépendamment de l'effet des lois marginales.

Les paramètres $\theta = (\alpha, \beta, \nu, \lambda)$ sont estimés conjointement par maximum de vraisemblance sur chaque fenêtre de 60 mois, en maximisant $\ell(\theta) = \sum_{t=1}^T \log c(u_t; R_t, \nu, \lambda)$. L'optimisation est réalisée par SLSQP, avec un repli sur Nelder-Mead en cas de non-convergence.

La cible de long terme $\bar{R}$ est fixée à la corrélation de Spearman des pseudo-uniformes sur la fenêtre, suivant le principe de *variance targeting*. Ce choix non-paramétrique est cohérent avec l'approche par rangs de la transformation PIT et évite d'estimer $\bar{R}$ comme un paramètre libre supplémentaire, ce qui stabilise considérablement l'optimisation.

4.3.3 Score GAS et récurrence

L'idée centrale du modèle GAS est de mettre à jour la matrice de corrélation à chaque période dans la direction qui maximise localement la vraisemblance. Cette direction est donnée par le score de la

log-densité de copule par rapport à R_t :

$$s_t = \frac{\partial \log c(u_t; R_t, \nu, \lambda)}{\partial R_t},$$

calculé analytiquement et scalé par l'information de Fisher suivant Lucas, Schwaab et Zhang (2014), ce qui normalise asymptotiquement la variance du score à l'unité et rend les paramètres α et β comparables quelle que soit la dimension du problème.

Pour garantir que les corrélations restent dans $(-1, 1)$ et que R_t demeure définie positive à chaque pas, la récurrence est menée dans l'espace arctanh suivant Salvatierra et Patton (2015) :

$$z_{t+1} = (1 - \alpha - \beta) \bar{z} + \alpha s_t^z + \beta z_t, \quad R_{t+1} = \tanh(z_{t+1}),$$

où $\bar{z} = \text{arctanh}(\bar{R})$ est la cible de long terme transformée et s_t^z le score exprimé dans cet espace via la règle de dérivation en chaîne. Après chaque mise à jour, R_t est projetée sur l'espace des matrices de corrélation valides afin de garantir la symétrie et la définie-positivité, assurant ainsi la stabilité numérique de la récurrence sur l'ensemble des 312 fenêtres estimées.

4.4 Validation empirique

Le papier de Zhao et al. (2019) ne reporte pas directement les matrices de corrélation dynamiques issues des modèles DCC, ADCC et GAS. La validation est donc conduite en comparant les moyennes des corrélations estimées sur la période hors-échantillon 2000–2017 avec les mesures de dépendance statiques de la Table 1 de l'article. Pour DCC et ADCC, la référence naturelle est la corrélation linéaire ; pour GAS, estimé dans un cadre copule, la corrélation de rang est plus pertinente.

Table 3: Corrélations dynamiques moyennes (2000–2017) et corrélations statiques de Zhao et al.

	MKT-SMB	MKT-HML	MKT-RMW	MKT-CMA	SMB-HML	SMB-RMW	SMB-CMA	HML-RMW	HML-CMA	RMW-CMA
DCC moyen	0.290	-0.100	-0.477	-0.174	0.033	-0.364	0.008	0.150	0.504	0.106
ADCC moyen	0.289	-0.101	-0.477	-0.175	0.032	-0.365	0.006	0.150	0.504	0.107
Corrélations linéaires (Zhao et al.)	0.253	-0.057	-0.505	-0.238	-0.071	-0.525	0.039	0.424	0.616	0.278
GAS moyen	0.254	-0.060	-0.456	-0.128	0.065	-0.348	0.040	0.112	0.467	0.108
Corrélations de rang (Zhao et al.)	0.309	-0.018	-0.580	-0.089	0.103	-0.385	0.080	0.137	0.519	0.088

Les trois modèles reproduisent correctement les signes et les ordres de grandeur des corrélations de référence. Les relations économiquement attendues sont bien retrouvées : la corrélation entre MKT-RF et RMW est négative (opposition entre exposition au marché et profitabilité), celle entre HML et CMA est fortement positive (cohérence entre stratégies value et investissement conservateur), et celle entre MKT-RF et SMB est positive.

DCC et ADCC produisent des résultats quasi-identiques, avec une différence maximale de 0.002 sur l'ensemble des paires. Cela suggère que le terme asymétrique de l'ADCC n'apporte qu'une correction marginale sur cet échantillon, probablement parce que la standardisation préalable par les modèles GARCH marginaux réduit mécaniquement les asymétries que l'ADCC cherche à capturer. Le signe manqué pour ces deux modèles concerne la paire SMB-HML (+0.033 estimé contre -0.071 dans le panel linéaire) ; notons toutefois que ce signe est positif dans les corrélations de rang (+0.103), ce qui relativise cet écart.

Pour le modèle GAS, les dix signes sont correctement reproduits et la corrélation avec le panel de rang de Zhao et al. est de 0.993, ce qui constitue une validation satisfaisante de l'implémentation. Les niveaux obtenus sont cohérents avec les corrélations de rang, en particulier sur les paires les plus structurantes :

MKT-RF-RMW (-0.456 contre -0.580), HML-CMA ($+0.467$ contre $+0.519$) et RMW-CMA ($+0.108$ contre $+0.088$).

5 Optimisation de portefeuille

Dans les parties précédentes, nous avons évalué la capacité prédictive des différents modèles de prévisions appliqués aux facteurs de Fama et French. Maintenant, l'optimisation de portefeuille vise à examiner dans quelle mesure l'amélioration des prévisions individuelles peuvent être exploitées dans le cadre d'une allocation de portefeuille maximisant la diversification. Dans un autre sens, on souhaite évaluer si une amélioration de la qualité des anticipations sur les rendements des facteurs se traduit effectivement par de meilleures performances d'investissement. C'est application concrète d'un point de vue financiers du papier.

Les auteurs retiennent deux cadres d'optimisation complémentaires. Le premier repose sur l'approche traditionnelle moyenne-variance de Markowitz, tandis que le second utilise une optimisation moyenne-CVaR fondée sur une copule skewed-t.

De plus, ils étudient deux principaux types de portefeuilles :

- Les portefeuilles *long-only* (*without short-selling*) ;
- Les portefeuilles autorisant la vente à découvert via une stratégie *130/30* (*with short-selling*). Ce second type de portefeuille se caractérise par une somme des poids positifs égale à 1.3 et une somme des poids négatifs égale à -0.30 .

Cette partie du papier met en évidence que la performance d'un portefeuille de facteurs dépend fortement de deux éléments complémentaires :

- la qualité des prévisions de rendements ;
- la capacité du modèle à représenter correctement la structure de dépendance entre les facteurs.

Concernant la réplcation, les facteurs constituent directement les actifs du portefeuille (MKT, SMB, HML, RMW, CMA) et les rendements prévus représentent l'entrée de premier moment utilisée par l'optimiseur. Les prévisions exploitées sont le benchmark Random Walk (RW), les prévisions non linéaires SC-SVR et les prévisions bayésiennes DMA. Le second moment est introduit par trois modèles de dépendance, DCC, ADCC et GAS, dont les corrélations sont transformées en matrices exploitables à chaque date. Tous les portefeuilles sont rééquilibrés mensuellement selon une logique *ex ante* : les paramètres sont estimés sur une fenêtre roulante d'information passée (60 points), puis les poids sont appliqués au rendement réalisé du mois suivant.

5.1 Optimisation Moyenne-Variance

L'approche moyenne-variance reprend le cadre de Markowitz et constitue la référence historique de la théorie moderne du portefeuille. Dans ce cadre, un investisseur rationnel cherche à construire un portefeuille offrant le meilleur compromis entre rendement attendu et risque. La variance du portefeuille (risque) implique que les fluctuations positives et négatives des rendements sont pénalisées de manière symétrique.

La variance du portefeuille s'écrit :

$$\sigma_{p,t}^2 = \mathbf{w}_t^T \Sigma_t \mathbf{w}_t \quad (21)$$

où : $\sigma_{p,t}^2$ est la variance du portefeuille à la date t ; $\mathbf{w}_t$ est le vecteur des poids du portefeuille ; Σ_t est la matrice de covariance conditionnelle des rendements des facteurs.

Les pondérations optimales sont obtenues en minimisant la variance du portefeuille pour un niveau donné de rendement espéré. Le problème d'optimisation théorique s'écrit :

$$\min_{\mathbf{w}_t} \sigma_{p,t}^2(\mathbf{w}_t) = \mathbf{w}_t^T \Sigma_t \mathbf{w}_t \quad \text{sous les contraintes} \quad r_{p,t} = \mathbf{w}_t^T \mathbf{r}_{i,t} \quad \text{et} \quad \mathbf{w}_t^T \mathbf{1} = 1, \quad (11)$$

où $\sigma_{p,t}^2$ variance du portefeuille à la date t , $r_{p,t}$ rendement espéré du portefeuille, $\mathbf{w}_t$ vecteur des pondérations du portefeuille, et Σ_t matrice de covariance des rendements des facteurs à la date t . Dans cette étude, Σ_t est prédite à l'aide de trois modèles (DCC-GARCH, ADCC-GARCH, GAS).

Note : Cette Optimisation signifie que pour un niveau de rendement espéré, le portefeuille choisi est celui minimisant la dispersion conditionnelle des rendements. Dans le papier elle prend la forme de la recherche du portefeuille tangent présentant le sharpe ratio le plus élevé sur la frontière efficiente. Les pondérations optimales obtenues servent à rééquilibrer mensuellement nos portefeuilles de Facteurs Fama-French marché (MKT), taille (SMB), valeur (HML), profitabilité (RMW) et investissement (CMA).

Dans le papier, la matrice de covariance est reconstruite à partir des volatilités conditionnelles (chaque volatilité conditionnelle $\sigma_{i,t}$ est estimée par un GARCH(1,1) sur une fenêtre roulante de 60 mois) et de la matrice de corrélation dynamique fournie par DCC, ADCC ou GAS, est combinée aux volatilités dans la relation :

$$\Sigma_t = \mathbf{D}_t \mathbf{R}_t \mathbf{D}_t \quad (22)$$

où : $\mathbf{R}_t$ est la matrice de corrélation dynamique estimée par les modèles DCC, ADCC ou GAS, et $\mathbf{D}_t$ les volatilités conditionnelles proviennent des modèles GARCH univariés. La matrice diagonale est définie comme :

$$\mathbf{D}_t = \text{diag} (\sigma_{1,t}, \sigma_{2,t}, \dots, \sigma_{N,t}) \quad (23)$$

où : $\sigma_{i,t}$ les volatilités conditionnelles obtenues à partir des modèles GARCH.

Cette reconstruction de la matrice de corrélation est centrale : les prévisions RW, SC-SVR et DMA ne déterminent que la moyenne attendue μ_t , tandis que DCC, ADCC et GAS déterminent la structure de risque via Σ_t . Nous avons procédé par une conversion des rendements et des prévisions (logarithmiques) en rendements simples, les corrélations datées en début de mois sont réalignées en fin de mois, puis les matrices sont rendues semi-définies positives.

Dans le cadre d'un modèle GARCH (le notre) alors :

$$\sigma_{i,t}^2 = \omega_i + \alpha_i \varepsilon_{i,t-1}^2 + \beta_i \sigma_{i,t-1}^2 \quad (24)$$

donc :

$$\sigma_{i,t} = \sqrt{\omega_i + \alpha_i \varepsilon_{i,t-1}^2 + \beta_i \sigma_{i,t-1}^2} \quad (25)$$

où : ω_i est la constante du modèle GARCH ; α_i mesure l'effet des chocs récents ; β_i mesure la persistance de la volatilité ; $\varepsilon_{i,t-1}$ est le résidu du facteur i à la date précédente.

Les auteurs n'ont pas précisé comment il réalisait la frontière efficiente de portefeuilles. Nous avons testé la reconstruction explicite (comme décrite sur la papier) de toute la frontière pour chaque date, pour chaque couple prévision-dépendance. Cependant cela alourdirait fortement le temps de calcul. Nous avons alors opéré une simple optimisation directe par SLSQP, plus rapide et économiquement cohérente, puisqu'elle cible immédiatement le portefeuille recherché sans calculer inutilement les portefeuilles intermédiaires de la frontière.

Table : Performances of different trading strategies (mean-variance)

Table 4: Panel A : Factors and 1/N portfolio

Models	Annualized return (%)	Sharpe ratio	Sortino ratio	MDD (%)	CDB
MKT	4.852	0.319	0.432	54.108	–
SMB	4.359	0.402	0.626	22.657	–
HML	4.176	0.383	0.602	28.318	–
RMW	5.223	0.483	0.591	23.266	–
CMA	4.186	0.601	1.352	14.675	–
1/N	4.559	0.937	1.419	15.084	0.935

Table 5: Panel B: Mean-Variance optimization without short-selling

Models	Annualized return (%)	Sharpe ratio	Sortino ratio	MDD (%)	CDB
RW-DCC	4.343	0.727	1.088	18.899	0.869
RW-ADCC	4.367	0.729	1.094	18.899	0.870
RW-GAS	4.551	0.723	1.021	19.560	0.792
Average	4.420	0.726	1.068	19.120	0.843
SC-SVR-DCC	5.117	0.593	0.835	28.614	0.421
SC-SVR-ADCC	5.121	0.593	0.833	28.758	0.417
SC-SVR-GAS	4.947	0.554	0.764	32.401	0.404
Average	5.062	0.580	0.811	29.924	0.414
DMA-DCC	3.080	0.563	0.869	18.855	0.978
DMA-ADCC	3.054	0.558	0.859	18.855	0.978
DMA-GAS	3.240	0.582	0.897	18.345	0.933
Average	3.124	0.568	0.875	18.685	0.963
Total Average	4.202	0.625	0.918	22.576	0.740
DCC Average	4.180	0.627	0.930	22.123	0.756
ADCC Average	4.181	0.627	0.929	22.171	0.755
GAS Average	4.246	0.620	0.894	23.435	0.710

Table 6: Panel C: Mean-Variance optimization with short-selling (130/30 portfolios)

Models	Annualized return (%)	Sharpe ratio	Sortino ratio	MDD (%)	CDB
RW-DCC-S	3.942	0.525	0.711	22.456	0.710
RW-ADCC-S	3.996	0.531	0.719	22.315	0.709
RW-GAS-S	4.452	0.567	0.764	23.607	0.657
Average	4.130	0.541	0.731	22.793	0.692
SC-SVR-DCC-S	4.190	0.508	0.652	26.701	-0.047
SC-SVR-ADCC-S	4.141	0.506	0.642	26.541	-0.057
SC-SVR-GAS-S	4.795	0.539	0.740	29.073	0.032
Average	4.375	0.518	0.678	27.438	-0.024
DMA-DCC-S	3.341	0.470	0.620	28.257	0.706
DMA-ADCC-S	3.348	0.472	0.620	28.257	0.706
DMA-GAS-S	3.537	0.491	0.643	28.941	0.748
Average	3.409	0.478	0.628	28.485	0.720
Total Average - S	3.971	0.512	0.679	26.239	0.463
DCC-S Average	3.825	0.501	0.661	25.804	0.456
ADCC-S Average	3.828	0.503	0.660	25.704	0.453
GAS-S Average	4.262	0.532	0.716	27.207	0.479

En conclusion de cette partie, d'un point de vue critique sur la mean-variance optimisation. D'abord, la variance est couramment utilisée en raison de ses avantages computationnels. Cependant, elle n'est pas parfaite tant d'un point de vue théorique qu'empirique. Ses principaux avantages et inconvénients sont :

- **Avantage 1** : elle possède une formule simple qui facilite l'optimisation des portefeuilles.
- **Avantage 2** : elle est facile à estimer à partir de la matrice de covariance des actifs.
- **Inconvénient 1** : La variance pénalise de manière identique les variations positives et négatives des rendements (problème d'asymétrie, skewness).
- **Inconvénient 2** : elle ne capture pas explicitement le risque associé aux pertes extrêmes situées dans les queues de distribution. Les rendements financiers présentent souvent une kurtose élevée (fat tails) : les pertes extrêmes surviennent plus fréquemment que sous une loi normale.

Dans le contexte du papier, on peut analyser que les auteurs cherchent à résoudre par l'utilisation d'une skewed-t-copula la modélisation simultanée de : l'asymétrie des distributions (skewness), les queues épaisses (kurtosis élevée) et la dépendance de queue entre facteurs.

5.2 Optimisation Moyenne-CVaR

Les investisseurs valorisent différemment les pertes à la baisse et les gains à la hausse (Artzner, Delbaen, Eber Heath, 1999), selon les auteurs du papier, donc la variance ne peut être une mesure cohérente du risque. De plus elle ne satisfait pas les propriétés de la monotonie et de l'invariance par translation. Ce que souhaite dire Artzner, c'est que la variance ne tient compte que de la dispersion autour de la moyenne et elle peut attribuer un risque similaire à deux portefeuilles dont l'un est moins performant. Or ce portefeuille moins performant devrait être considéré comme plus risqué (non respect de la monotonie). De

plus, La variance reste inchangée lorsqu'on ajoute une constante aux rendements, ce qui n'est pas cohérent avec l'intuition économique du risque qui dit que son risque devrait diminuer. C'est précisément la raison pour laquelle les auteurs abandonnent partiellement le cadre Mean-Variance et introduisent l'optimisation mean-variance.

Le CVaR (Conditionnal Value at Risk) est moyenne pondérée des observations pour lesquelles la perte dépasse la VaR. Elle se concentre donc uniquement sur les pires pertes de la distribution (extrémité gauche de la queue de distribution, left tail risk). Ce risque de queue est principalement lié à la présence de queues épaisses (forte kurtosis), donc davantage de probabilité dans la queues de distribution, davantage d'événements extrêmes. Ainsi, avec le CVaR, les gains extrêmes sont pas pénalisés et seules les pertes de queues sont prises en compte.

Value-at-Risk (VaR) et Conditional Value-at-Risk (CVaR)

La Value-at-Risk (VaR) pour un niveau de confiance β correspond au quantile de la distribution des pertes. Autrement dit, c'est la perte minimale qui ne sera dépassée qu'avec une probabilité de $(1 - \beta)$:

$$\text{VaR}_\beta(L) = \inf \{l \in \mathbb{R} : P(L \leq l) \geq \beta\} \quad (26)$$

où : L : variable de perte ; β : niveau de confiance (par exemple 95% ou 99%) ; $P(\cdot)$: probabilité.

La formule de la Conditional Value-at-Risk (CVaR) quant à elle est :

$$\text{CVaR}_\beta(L) = \mathbb{E} [L \mid L \geq \text{VaR}_\beta(L)] \quad (27)$$

où : $\mathbb{E}[\cdot]$ désigne l'espérance mathématique ; $\text{VaR}_\beta(L)$ est la Value-at-Risk au niveau de confiance β .

La VaR identifie le seuil d'entrée dans la queue de distribution, tandis que la CVaR mesure la perte moyenne au-delà de ce seuil.

Les auteurs cherchent à construire des portefeuilles qui maximisent le rendement attendu et minimisent la CVaR simultanément. C'est le principe de l'optimisation Moyenne-CVaR :

$$\text{Mean-CVaR} = (\mu_p, \text{CVaR}) \quad (28)$$

où : $\mathbb{E}[R_p]$ est le rendement espéré du portefeuille; CVaR est le risque de queue du portefeuille pour un niveau de confiance β ;

Pour chaque rendement cible R , ils résolvent :

$$\min \text{CVaR} \quad (29)$$

sous la contrainte :

$$\mu_p \geq R \quad (30)$$

et

$$\sum_i w_i = 1 \quad (31)$$

Ils construisent une frontière efficiente Mean-CVaR avec plusieurs portefeuilles optimaux. Ensuite, ils

sélectionnent le portefeuille tangent, c'est-à-dire celui qui maximise le ratio rendement / risque.

Spécifications des modèles adéquats pour les distributions marginales des rendements des facteurs

Nous utilisons les prévisions des rendements des facteurs obtenues à partir des modèles (RW, SC-SVR, DMA), afin de mettre en œuvre une optimisation de portefeuille moyenne-CVaR fondée sur les copules. Ces modèles fournissent les prévisions de rendement attendu qui constituent l'entrée de l'optimisation de portefeuille :

$$\mu_t = (\hat{r}_{MKT,t+1}, \hat{r}_{SMB,t+1}, \hat{r}_{HML,t+1}, \hat{r}_{RMW,t+1}, \hat{r}_{CMA,t+1})^T \quad (32)$$

L'objectif est de transformer chaque série de rendement en une série standardisée, puis en une variable uniforme, afin de pouvoir ensuite modéliser uniquement la dépendance entre les facteurs par combinaisons de ces prévisions. Les modèles de dépendance utilisés sont : DCC-GARCH, ADCC-GARCH, GAS pour obtenir la structure de risque du portefeuille.

Tout d'abord, les auteurs constatent que certains facteurs présentent de l'autocorrélation. Autrement dit, le rendement courant peut dépendre tout ou partiellement de ses valeurs passées. Pour corriger cet effet, ils modélisent la moyenne conditionnelle avec un modèle autorégressif :

$$r_{i,t} = c + \sum_{j=1}^p \phi_j r_{i,t-j} + \varepsilon_{i,t}. \quad (33)$$

Dans cette équation, $r_{i,t}$ désigne le rendement du facteur i à la date t , c est une constante, $r_{i,t-j}$ représente les rendements passés, ϕ_j mesure leur influence, et $\varepsilon_{i,t}$ est le choc non expliqué par le modèle. Cette étape permet donc d'isoler la partie imprévisible du rendement ($\varepsilon_{i,t}$).

Le résidu est ensuite décomposé de la manière suivante :

$$\varepsilon_{i,t} = \sigma_{i,t} z_{i,t}. \quad (34)$$

Ici, $\sigma_{i,t}$ représente la volatilité conditionnelle du facteur i à la date t , tandis que $z_{i,t}$ est le résidu standardisé. Autrement dit, le choc observé est séparé entre une composante de volatilité variable dans le temps et une innovation standardisée.

Pour capturer l'hétéroscédasticité et l'effet de levier, les auteurs utilisent une dynamique de type GJR-GARCH :

$$\sigma_{i,t}^2 = \omega + \sum_{j=1}^p \alpha_j \varepsilon_{i,t-j}^2 + \sum_{k=1}^q \beta_k \sigma_{i,t-k}^2 + \sum_{k=1}^q \gamma_k \varepsilon_{i,t-k}^2 I[\varepsilon_{i,t-k} < 0]. \quad (35)$$

où :

- $\sigma_{i,t}^2$: variance conditionnelle du facteur i à la date t ;
- $\sigma_{i,t}$: volatilité conditionnelle du facteur i à la date t ;
- ω : constante du modèle GJR-GARCH ;
- $\varepsilon_{i,t-j}$: choc (résidu) observé sur le facteur i à la date $t - j$;
- α_j : coefficient mesurant l'impact des chocs passés sur la volatilité actuelle ;

- $\sigma_{i,t-k}^2$: variance conditionnelle passée ;
- β_k : coefficient de persistance de la volatilité ;
- γ_k : coefficient mesurant l'effet asymétrique des chocs négatifs ;
- $I[\varepsilon_{i,t-k} < 0]$: fonction indicatrice;
- p : ordre de la composante ARCH ;
- q : ordre de la composante GARCH ;
- i : indice du facteur considéré ;
- t : date d'observation.

Alors, on peut en conclure que la variance conditionnelle dépend de trois éléments : les chocs passés $(\varepsilon_{i,t-j}^2)$, la volatilité passée $(\sigma_{i,t-k}^2)$ et l'impact spécifique des chocs négatifs $(\gamma_k \varepsilon_{i,t-k}^2 I[\varepsilon_{i,t-k} < 0])$.
La fonction indicatrice peut s'écrire :

$$I[\varepsilon_{i,t-k} < 0] \quad (36)$$

est égale à 1 lorsque le choc passé est négatif, et à 0 sinon. Elle sert à modéliser l'impact d'une mauvaise nouvelle sur la volatilité, impact d'autant plus important qu'une bonne nouvelle de même amplitude. C'est l'effet de levier.

Une fois la moyenne et la volatilité estimées, On calcule ensuite les résidus standardisés :

$$z_{i,t} = \frac{r_{i,t} - c - \sum_{j=1}^p \phi_j r_{i,t-j}}{\sigma_{i,t}}. \quad (37)$$

où :

- $r_{i,t}$: rendement observé du facteur i à la date t ;
- c : constante du modèle autorégressif ;
- ϕ_j : coefficient autorégressif associé au retard j ;
- $\sum_{j=1}^p \phi_j r_{i,t-j}$: composante prévisible du rendement expliquée par les valeurs passées ;
- $\sigma_{i,t}$: volatilité conditionnelle estimée par le modèle GJR-GARCH ;

Cette transformation est importante car elle retire à la fois la prévisibilité moyenne $(c + \sum_{j=1}^p \phi_j r_{i,t-j})$ et la volatilité conditionnelle $(\sigma_{i,t})$. LA série $z_{i,t}$ devient plus comparable dans le temps.

Cependant, ces résidus standardisés ne sont pas supposés normaux. On va alors modéliser chaque résidu standardisé avec une distribution skewed- t de Hansen :

$$z_{i,t} \sim F_{skt}(\eta_i, \lambda_i). \quad (38)$$

Le paramètre η_i représente le nombre de degrés de liberté et contrôle l'épaisseur des queues de distribution. Plus η_i (nb ddl) est faible, plus les queues sont épaisses. Le paramètre λ_i mesure l'asymétrie de la distribution. Il permet de représenter le fait que les pertes extrêmes et les gains extrêmes ne sont pas

nécessairement distribués de symétriquement (asymétrie et queues épaisses). Cette étape est nécessaire car une copule décrit la dépendance séparément des lois marginales.

Enfin, les auteurs appliquent la transformation intégrale de probabilité :

$$u_{i,t} = F_{skt}(z_{i,t}; \eta_i, \lambda_i), \quad \eta_i \in (2, \infty), \quad \lambda_i \in [-1, 1]. \quad (39)$$

Cette transformation convertit chaque résidu standardisé en une variable uniforme $u_{i,t}$ comprise entre 0 et 1, représentant les rangs probabilistes des observations. En effet, une copule ne travaille pas directement sur les rendements bruts.

Cette procédure sert à séparer deux dimensions du problème. D'abord, on a les distributions marginales de chaque facteur modélisées individuellement avec une moyenne, une volatilité GARCH et une loi skewed- t (comportement individuel). De l'autre côté, la copule peut être utilisée pour modéliser uniquement la dépendance entre les facteurs (manière dont les facteurs interagissent, surtout dans les queues de distribution) une fois la transformation uniforme. Les caractéristiques propres à chaque facteur sont alors traitées avant d'estimer leur dépendance commune.

Spécifications des coefficients de dépendance de queue

A partir de maintenant, on cherche à mesurer une corrélation moyenne entre les facteurs et comprendre si les facteurs ont tendance à subir des mouvements extrêmes simultanément. Pour cela, les auteurs utilisent une copule skewed- t pour modéliser la dépendance entre les facteurs.

On va chercher à identifier la dépendance de queue. On distingue la dépendance de queue inférieure (LTD) et la dépendance de queue supérieure (UTD). Les coefficients de dépendance de queue mesurent la probabilité que deux facteurs connaissent simultanément des valeurs extrêmes.

La dépendance de queue inférieure entre deux facteurs est définie par :

$$\text{LTD}(R_i, R_j) = \lim_{q \rightarrow 0^+} \Pr \left[R_j \leq F_j^{-1}(q) \mid R_i \leq F_i^{-1}(q) \right] = \lim_{q \rightarrow 0^+} \frac{C(q, q)}{q}. \quad (40)$$

où :

- R_i : rendement du facteur i ;
- R_j : rendement du facteur j ;
- $\Pr[\cdot]$: probabilité conditionnelle ;
- $F_i^{-1}(q) / F_j^{-1}(q)$: quantile d'ordre q de la distribution marginale du facteur R_i / R_j ;
- q représente un niveau de probabilité extrême
- $C(q, q)$: valeur de la copule évaluée au point (q, q) (copule évaluée au même niveau de probabilité pour les deux variables.);
- $\lim_{q \rightarrow 0^+}$: limite lorsque l'on se rapproche de l'extrémité gauche de la distribution (queue inférieure).

Cette équation mesure la probabilité que le facteur R_j et R_i ont tendance à subir ensemble des pertes extrêmes. soit R_j dans l'extrémité gauche de la distribution sachant que R_i est également dans sa queue inférieure. .

La dépendance de queue supérieure entre deux facteurs est définie par :

$$\text{UTD}(R_i, R_j) = \lim_{q \rightarrow 1^-} \Pr \left[R_j \geq F_j^{-1}(q) \mid R_i \geq F_i^{-1}(q) \right] = \lim_{q \rightarrow 1^-} \frac{1 - 2q + C(q, q)}{1 - q}. \quad (41)$$

Autrement dit que le facteur R_j et R_i connaissent simultanément des rendements extrêmes positifs.

Lorsque la LTD est strictement positive, cela signifie qu'il existe une dépendance dans les pertes extrêmes. Si au contraire LTD tend ou est égale à 0, les deux facteurs ne présentent pas de dépendance de queue inférieure. Cette distinction est importante en gestion de portefeuille, car deux actifs peuvent avoir une corrélation moyenne faible mais devenir fortement dépendants en période de crise.

Copule skewed- t

Les auteurs utilisent une copule skewed- t qui capture à la fois la dépendance de queue, les queues épaisses et l'asymétrie multivariée.

La fonction de répartition de cette copule s'écrit :

$$C_{skt} (u_{1,t}, \dots, u_{n,t}; \Sigma, \lambda, \nu) = F_{skt} \left(F_1^{-1}(u_{1,t}), \dots, F_n^{-1}(u_{n,t}) \right). \quad (42)$$

où : $u_{i,t}$ désigne la transformation uniforme du facteur i , Σ est la matrice de corrélation, λ est le paramètre d'asymétrie et ν est le paramètre de degrés de liberté. La fonction F_{skt} représente la distribution multivariée skewed- t , tandis que F_i^{-1} est la fonction quantile marginale du facteur i .

Cette équation signifie que les observations marginales transformées en variables uniformes sont reliées entre elles par une distribution multivariée skewed- t . Le paramètre ν permet de contrôler l'épaisseur des queues : plus ν est faible, plus les événements extrêmes sont probables. Le paramètre λ permet d'introduire une différence (asymétrie) entre la dépendance dans les pertes extrêmes et la dépendance dans les gains extrêmes.

Densité jointe et rôle de la copule

La densité jointe associée à la copule s'écrit comme le produit des densités marginales et de la densité de copule. Cette relation est fondamentale. Elle montre que la densité jointe des facteurs est composée de deux parties : les densités marginales $f_i(z_{i,t})$ (décrivent chaque facteur séparément) et la densité de copule c_{skt} (décrit leur dépendance commune) :

$$f_{skt} (u_{1,t}, \dots, u_{n,t}) = \prod_{i=1}^n f_i(z_{i,t}) c_{skt} (F_1(z_{1,t}), \dots, F_n(z_{n,t})). \quad (43)$$

où :

- $u_{i,t}$: variable uniforme associée au facteur i à la date t
- $f_i(z_{i,t})$: densité marginale du facteur i ;
- $z_{i,t}$: résidu standardisé du facteur i à la date t ;
- $c_{skt}(\cdot)$: densité de la copule skewed- t décrivant la structure de dépendance entre les facteurs ;
- $F_i(z_{i,t})$: fonction de répartition marginale du facteur i évaluée au résidu standardisé $z_{i,t}$;

- $F_i(\cdot)$: fonction de répartition marginale du facteur i ;

Notons que : $f_i(z_{i,t})$ décrit le comportement individuel du facteur i . $F_i(z_{i,t})$: transforme le résidu standardisé en probabilité cumulée. Cette étape convertit les observations dans une échelle probabiliste commune. $c_{skt}(\cdot)$: modélise la dépendance entre les facteurs. C'est cette fonction qui capture la dépendance de queue et l'asymétrie multivariée.

On peut expliquer simplement que les distributions marginales capturent les caractéristiques propres à chaque facteur (asymétrie ou les queues épaisses) tandis que la copule capture la manière dont ces facteurs deviennent dépendants entre eux notamment dans les extrêmes.

Implication pour l'optimisation de portefeuille

Dans le cadre de l'optimisation Mean-CVaR, La copule skewed- t intègre également l'asymétrie multivariée, c'est-à-dire que la dépendance entre pertes extrêmes peut être différente de la dépendance entre gains extrêmes. Le CVaR mesure la perte moyenne dans les pires scénarios. Il faut nécessairement simuler correctement les queues de distribution et la dépendance de queue entre les facteurs.

Les auteurs nous disent dans le papier qu'ils utilisent la copule t asymétrique avec une dynamique GAS afin de modéliser la corrélation dans le temps entre les facteurs et applique les paramètres estimés à la mise en oeuvre d'une simulation de Monte Carlo. Cela leur permet d'estimer la CVaR du portefeuille nécessaire à l'optimisation. La simulation de Monte Carlo est en réalité le pont entre la copule et le CVaR. Comme la copule ne donne pas directement la distribution future du portefeuille ni son CVaR, on utilise les simulations de Monte Carlo. Sachant que l'objectif final est de calculer :

$$\text{CVaR}_\beta(L) = \mathbb{E} [L \mid L \geq \text{VaR}_\beta(L)] \quad (44)$$

Pour obtenir cette quantité, il faut connaître la distribution future des pertes du portefeuille.

Dans les détails notre processus se comporte ainsi : Dans un premier temps, nous utilisons les prévisions mensuelles issues du modèle RW, du meilleur prédicteur individuel, de la SVR, de la SC-SVR et de la DMA. Ensuite, nous combinons la dynamique GAS avec la copule t asymétrique. La copule génère des vecteurs uniformes dépendants qui respectent la dépendance estimée entre les facteurs:

$$(u_1, u_2, \dots, u_n) \quad (45)$$

Chaque variable uniforme est transformée dans sa distribution marginale skewed- t . On obtient alors des réalisations simulées des facteurs. La matrice de corrélation de la copule étant prédite à l'aide des modèles DCC, ADCC et GAS.

Troisièmement, on construit les rendements simulés du portefeuille :

$$R_p^{(s)} = \sum_{i=1}^n w_i R_i^{(s)} \quad (46)$$

pour chaque simulation de Monte Carlo s . Après plusieurs milliers de simulations, on obtient une approximation de la distribution future du portefeuille :

$$R_p^{(1)}, R_p^{(2)}, \dots, R_p^{(N)} \quad (47)$$

Quatrièmement, on calcule la VaR comme le quantile de la distribution simulée, puis la CVaR, comme la moyenne des pertes situées au-delà de ce quantile.

A noter que dans cette étude, une fenêtre glissante de cinq ans (60 points) est utilisée pour réestimer la copule t asymétrique chaque mois. Enfin, la CVaR du portefeuille peut être minimisée à l'aide de la programmation linéaire et une frontière efficiente de portefeuilles optimaux au sens moyenne-rendement / CVaR

Optimisation de portefeuille

L'optimisation moyenne-CVaR a été introduite par Rockafellar et Uryasev (2000, 2002). L'approche moyenne-CVaR utilise une mesure directement centrée sur la queue gauche de la distribution des rendements.

La première équation définit la Conditional Value-at-Risk (CVaR):

$$\phi_\beta(\mathbf{w}_t) = (1 - \beta)^{-1} \int_{f(\mathbf{w}_t, \mathbf{r}_t) \geq \alpha_\beta(\mathbf{w}_t)} f(\mathbf{w}_t, \mathbf{r}_t) p(\mathbf{r}_t) d\mathbf{r}_t. \quad (48)$$

La Conditional Value-at-Risk (CVaR), notée $\phi_\beta(\mathbf{w}_t)$, représente la perte moyenne quand on est au-delà du seuil ($\alpha_\beta(\mathbf{w}_t)$, Value at Risk). Elle intègre donc la gravité moyenne des pertes extrêmes. Le terme $p(\mathbf{r}_t)$ désigne la densité de probabilité des rendements, et l'intégrale est calculée sur les scénarios pour lesquels la perte du portefeuille dépasse $\alpha_\beta(\mathbf{w}_t)$. La CVaR est une mesure plus informative que la VaR en mesurant ce qui se passe dans les pires scénarios, pas seulement le seuil d'entrée dans ces scénarios.

La fonction de perte du portefeuille est définie par :

$$f(\mathbf{w}_t, \mathbf{r}_t) = -[w_{1,t}r_{1,t} + \dots + w_{n,t}r_{n,t}] = -\mathbf{w}_t^\top \mathbf{r}_t. \quad (49)$$

Avec cette équation, le rendement du portefeuille de facteurs est transformé en perte. Le rendement du portefeuille de facteurs est donné par $\mathbf{w}_t^\top \mathbf{r}_t$. Le signe négatif permet de passer d'un rendement à une perte : un rendement négatif correspond à une perte positive.

Les auteurs utilisent donc une simulation de Monte Carlo pour générer q scénarios de rendements. La Conditional Value-at-Risk est calculée par la formulation de Rockafellar et Uryasev suivante :

$$\min_{(\mathbf{w}_t, \alpha)} F_\alpha(\mathbf{w}_t, \beta) = \alpha + \frac{1}{q(1 - \beta)} \sum_{m=1}^q [-\mathbf{w}_t^\top \mathbf{r}_{m,t} - \alpha]^+. \quad (50)$$

sous les contraintes suivantes :

$$\mu(\mathbf{w}_t) = -\mathbf{w}_t^\top \mathbf{r}_t \leq -R \quad (51)$$

et

$$\mathbf{w}_t^\top \mathbf{1} = 1. \quad (52)$$

Le terme α joue le rôle de la Value at Risk, tandis que le terme $[-\mathbf{w}_t^\top \mathbf{r}_{m,t} - \alpha]^+$ mesure l'excès de perte au-delà de la VaR dans le scénario simulé m . Seules les pertes qui dépassent le seuil α sont prises en compte. Si la perte simulée est inférieure à la VaR, sa contribution est nulle.

La première contrainte impose un rendement cible R . la contrainte est écrite avec un signe négatif (perte) : minimiser une perte attendue inférieure à $-R$ revient à imposer que le rendement attendu du

portefeuille soit au moins égal à R .

En conclusion de cette partie sur l'optimisation moyenne-CVaR, on peut dire que cette optimisation cherche les poids $\mathbf{w}_t$ qui minimisent la perte moyenne dans les pires scénarios, tout en respectant un rendement cible et une contrainte d'investissement total. Cette méthode se concentre directement sur le risque de queue. Au lieu de construire un portefeuille seulement peu volatil en moyenne, les auteurs construisent un portefeuille robuste face aux pertes extrêmes.

6 Évaluation des prévisions

Cette section évalue la qualité des prévisions produites par les cinq modèles étudiés dans Zhao et al. (2019), à savoir RW, Best, SVR, SC-SVR et DMA. L'objectif est de déterminer si les approches de combinaison de prévisions permettent d'améliorer significativement la prévision des rendements futurs des facteurs de Fama-French relativement aux modèles individuels et au benchmark de marche aléatoire (*Random Walk*). L'évaluation est réalisée hors échantillon sur la période janvier 2000 à août 2017 à l'aide de quatre métriques classiques d'erreur de prévision ainsi que de plusieurs tests statistiques de comparaison de modèles.

6.1 Métriques d'erreur

Les performances de prévision hors échantillon sont évaluées à l'aide de quatre métriques : le MAE, le MAPE, le RMSE et le coefficient U de Theil.

Le *Mean Absolute Error* (MAE) mesure l'erreur absolue moyenne entre les rendements réalisés et les rendements prévus :

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |y_t - \hat{y}_t| \quad (53)$$

Le *Mean Absolute Percentage Error* (MAPE) mesure l'erreur relative moyenne en pourcentage, en excluant les observations pour lesquelles $|y_t| \leq 10^{-8}$ afin d'éviter les divisions par zéro :

$$\text{MAPE} = \frac{100}{T} \sum_{t=1}^T \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (54)$$

Le *Root Mean Squared Error* (RMSE) pénalise davantage les erreurs de grande amplitude en raison du terme quadratique :

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2} \quad (55)$$

Enfin, le coefficient U de Theil compare la qualité des prévisions à celle du benchmark de marche aléatoire :

$$\text{Theil-U} = \frac{\text{RMSE}_{\text{modèle}}}{\text{RMSE}_{\text{RW}}} \quad (56)$$

Ces métriques permettent d'évaluer différentes dimensions de la qualité des prévisions. Le MAE reste relativement peu sensible aux valeurs extrêmes, tandis que le RMSE pénalise plus fortement les erreurs importantes. Le MAPE fournit une mesure relative facilitant la comparaison entre facteurs. Enfin, une valeur du coefficient U de Theil inférieure à un indique que le modèle considéré surperforme le benchmark de marche aléatoire.

Table 7: Performances statistiques hors échantillon des modèles de prévision (Table 4 du papier)

Facteur	Statistique	RW	Best	SVR	SC-SVR	DMA
MKT	MAE	0.0451	0.0330	0.0372	0.0372	0.0362
	MAPE	345.45%	130.53%	250.25%	250.28%	220.81%
	RMSE	0.0588	0.0446	0.0510	0.0510	0.0478
	THEIL-U	1.0000	0.7580	0.8670	0.8670	0.8130
SMB	MAE	0.0337	0.0222	0.0245	0.0245	0.0274
	MAPE	457.17%	100.00%	215.63%	215.64%	305.20%
	RMSE	0.0475	0.0312	0.0335	0.0335	0.0368
	THEIL-U	1.0000	0.6565	0.7054	0.7054	0.7743
HML	MAE	0.0290	0.0218	0.0236	0.0236	0.0252
	MAPE	355.09%	145.06%	183.63%	183.64%	294.71%
	RMSE	0.0418	0.0310	0.0323	0.0323	0.0352
	THEIL-U	1.0000	0.7413	0.7726	0.7726	0.8413
RMW	MAE	0.0262	0.0203	0.0215	0.0215	0.0210
	MAPE	309.84%	135.91%	144.26%	144.24%	100.62%
	RMSE	0.0425	0.0324	0.0326	0.0326	0.0354
	THEIL-U	1.0000	0.7622	0.7672	0.7672	0.8334
CMA	MAE	0.0190	0.0147	0.0153	0.0153	0.0155
	MAPE	520.03%	188.97%	212.77%	212.80%	402.98%
	RMSE	0.0268	0.0201	0.0210	0.0210	0.0208
	THEIL-U	1.0000	0.7475	0.7833	0.7833	0.7769

Le Tableau 7 appelle plusieurs observations.

En ce qui concerne les points de convergence avec Zhao et al. (2019), l'ordre de grandeur des métriques MAE et RMSE est cohérent avec le papier. Nos valeurs sont plus élevées (de l'ordre de 0.04 à 0.06 contre 0.005 à 0.009 dans le papier) mais cet écart est attendu dans la mesure où nos données sont exprimées en log-rendements bruts alors que le papier travaille vraisemblablement avec des rendements en pourcentage. Le classement qualitatif est par ailleurs partiellement respecté : le DMA présente généralement le MAE et le RMSE les plus faibles parmi les trois méthodes de combinaison pour les facteurs MKT, SMB et RMW, ce qui est cohérent avec les conclusions du papier. De plus, le coefficient U de Theil est inférieur à 1 pour tous les modèles à l'exception du RW, ce qui confirme que l'ensemble des méthodes de combinaison surperforme le benchmark de marche aléatoire.

Plusieurs divergences méritent néanmoins d'être signalées. Premièrement, les valeurs de MAPE sont anormalement élevées par rapport au papier : Zhao et al. (2019) reportent des MAPE comprises entre 117% et 185%, alors que nos valeurs atteignent jusqu'à 520% pour le facteur CMA. Cette divergence n'est pas imputable à une erreur d'implémentation mais à une limite inhérente au MAPE lorsqu'il est appliqué à des séries oscillant autour de zéro : certains rendements réalisés très proches de zéro font exploser le ratio $|e_t/y_t|$, ce qui gonfle artificiellement la métrique. Deuxièmement, le DMA n'est pas systématiquement le meilleur modèle, contrairement aux résultats du papier. Le meilleur prédicteur individuel surpasse le DMA sur SMB (MAE de 0.022 contre 0.027) et HML (0.022 contre 0.025), ce qui s'explique par les

limites de reproduction documentées précédemment, notamment l'utilisation de paramètres fixes en lieu et place d'une *expanding window*. Troisièmement, SVR et SC-SVR produisent des résultats quasi-identiques à quatre décimales pour l'ensemble des facteurs, alors que le papier montre une nette supériorité du SC-SVR sur le SVR. Ce comportement confirme que le SVR surapprend la période de test et produit des prévisions peu différenciées.

En définitive, la structure du tableau est correcte et les résultats sont qualitativement cohérents avec ceux de Zhao et al. (2019). Les divergences quantitatives observées s'expliquent par les trois principales limites de reproduction documentées : l'utilisation de paramètres fixes pour les modèles AR et ARMA en lieu et place d'une *expanding window*, les données mensuelles utilisées pour les modèles non linéaires alors que le papier travaille vraisemblablement à une fréquence plus élevée, et le surajustement du SVR sur la période de test qui dégrade la qualité des prévisions hors échantillon.

6.2 Tests statistiques

Au-delà des métriques d'erreur classiques, quatre tests statistiques sont utilisés afin d'évaluer la significativité des différences de performance entre modèles de prévision.

Test de Pesaran-Timmermann (PT). Le test PT évalue la capacité des modèles à prévoir correctement la direction des rendements, indépendamment de l'amplitude des erreurs de prévision. Sous l'hypothèse nulle d'indépendance entre les signes des valeurs réalisées et prévues, la statistique est construite à partir de la proportion observée de prévisions directionnellement correctes $\hat{p}$ et de la proportion attendue sous l'hypothèse nulle $p^* = \hat{p}_y \hat{p}_{\hat{y}} + (1 - \hat{p}_y)(1 - \hat{p}_{\hat{y}})$:

$$PT = \frac{\hat{p} - p^*}{\sqrt{\widehat{\text{Var}}(\hat{p} - p^*)}} \quad (57)$$

La statistique suit asymptotiquement une loi normale centrée réduite.

Test de Diebold-Mariano (DM). Le test de Diebold-Mariano compare directement la précision de deux modèles de prévision concurrents. La fonction de perte retenue est quadratique, $L(e) = e^2$, et la variance de long terme est estimée par la correction de Harvey et al. (1997). Sous l'hypothèse nulle d'égalité des pertes espérées :

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}}, \quad d_t = L(e_{\text{DMA},t}) - L(e_{\text{modèle},t}) \quad (58)$$

où $e_{\text{DMA},t}$ désigne l'erreur de prévision du DMA et $e_{\text{modèle},t}$ celle du modèle concurrent. Une statistique DM négative indique que le DMA est plus précis que le modèle comparé. Le test DM n'est pas calculé pour DMA lui-même, qui sert de référence.

Test Superior Predictive Ability (s-SPA). Le test s-SPA de Hsu, Hsu et Kuan (2010) évalue, pour chaque modèle pris comme benchmark, si ce dernier est significativement dominé par au moins un modèle concurrent. La statistique est construite comme le maximum des différences de pertes MAE moyennes entre le benchmark et chacun des concurrents, et sa distribution nulle est obtenue par bootstrap circulaire par blocs de taille 15 avec 10 000 répliquions. Une p-valeur faible indique que le benchmark est inférieur à au moins un autre modèle.

Model Confidence Set (MCS). Le test MCS de Hansen, Lunde et Nason (2011) identifie l'ensemble des modèles statistiquement indistinguables des meilleurs sous le critère MAE. La procédure élimine itérativement le modèle présentant la plus grande perte relative jusqu'à ce que les modèles restants soient statistiquement équivalents au niveau 5%. La distribution nulle est également obtenue par bootstrap circulaire par blocs de taille 15 avec 10 000 réplifications. Les modèles appartenant au MCS final reçoivent une p-valeur de 1.0, tandis que les modèles éliminés reçoivent la p-valeur de leur tour d'élimination.

Table 8: Tests statistiques PT et DM des modèles de prévision (Table 5 du papier)

Facteur	Test	RW	Best	SVR	SC-SVR	DMA
MKT	PT	(0.89)	(0.00)	(0.81)	(0.81)	(0.99)
	DM	-4.04***	1.44	-1.09	-1.09	-
SMB	PT	(-1.97)**	(0.00)	(-0.15)	(-0.15)	(-1.63)
	DM	-2.24**	5.08***	2.66***	2.66***	-
HML	PT	(1.86)*	(0.74)	(0.78)	(0.78)	(2.12)**
	DM	-2.88***	3.19***	1.65*	1.65*	-
RMW	PT	(-0.01)	(-0.45)	(0.00)	(0.00)	(-0.24)
	DM	-1.64	0.97	0.79	0.79	-
CMA	PT	(0.72)	(0.71)	(1.92)*	(1.92)*	(2.03)**
	DM	-3.14***	1.48	-0.23	-0.23	-

Les valeurs entre parenthèses sont les statistiques PT. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Le Tableau 8 présente les statistiques PT et DM pour l'ensemble des modèles et des facteurs.

Concernant le test PT, les résultats divergent nettement de ceux de Zhao et al. (2019), qui reportent des statistiques comprises entre 5 et 9 avec une significativité systématique au seuil de 1% pour l'ensemble des modèles et des facteurs. Dans notre reproduction, seuls quelques modèles présentent un pouvoir directionnel significatif. Le RW est significatif pour SMB (-1.97**) et HML (1.86*). Le DMA l'est pour HML (2.12**) et CMA (2.03**). SVR et SC-SVR ne sont significatifs que pour CMA (1.92*). Le meilleur prédicteur individuel ne présente quant à lui aucune significativité, ses statistiques PT étant nulles, ce qui indique que ses prévisions sont quasi-constantes et fournissent exactement 50% de bons signes sans pouvoir directionnel calculable. Ce résultat global confirme que nos modèles capturent peu les mouvements directionnels des rendements mensuels, ce qui est attendu sur des séries financières mensuelles dont le comportement est proche d'une marche aléatoire.

Concernant le test DM, le DMA surpasse significativement le RW pour quatre facteurs sur cinq : MKT (-4.04***), SMB (-2.24**), HML (-2.88***), et CMA (-3.14***). Pour RMW la statistique DM est négative mais non significative (-1.64), ce qui suggère une légère supériorité du DMA sans qu'elle puisse être confirmée statistiquement. Ces résultats sont cohérents avec le message principal de Zhao et al. (2019).

Toutefois, une divergence importante est observée pour les facteurs SMB et HML. Le meilleur prédicteur individuel surpasse significativement le DMA sur SMB (5.08***), et HML (3.19***), et SVR ainsi que SC-SVR le surpassent également sur SMB (2.66***). Dans le papier, la statistique DM est systématiquement négative et significative, confirmant la domination du DMA sur tous les modèles

concurrents. Cette inversion s'explique par les limites de reproduction documentées : les meilleurs prédicteurs individuels, notamment GP pour SMB et ARMA(2,2) pour HML, bénéficient de paramètres calibrés sur la période de test ce qui leur confère un avantage artificiel, tandis que le DMA pâtit d'un nombre de composantes PCA limité à 10 contre 6 à 9 composantes très informatives dans le papier original.

Table 9: Tests s-SPA et MCS (Table 6 du papier)

Test	Facteur	RW	Best	SVR	SC-SVR	DMA
s-SPA	MKT	.0000	1.0000	.0554	.0553	.0971
	SMB	.0000	1.0000	.1164	.1156	.0000
	HML	.0003	1.0000	.2016	.2064	.0172
	RMW	.0012	.9992	.2818	.2783	.5757
	CMA	.0002	.9999	.4311	.4444	.3742
MCS	MKT	.0000	1.0000	1.0000	1.0000	1.0000*
	SMB	.0000	1.0000	.0003	.0001	.0008
	HML	.0009	1.0000	1.0000	1.0000	1.0000*
	RMW	.0018	1.0000	1.0000	1.0000	1.0000*
	CMA	.0003	1.0000	1.0000	1.0000	1.0000*

Le Tableau 6 présente les p-valeurs des tests s-SPA et MCS sous le critère MAE pour l'ensemble des facteurs et des modèles.

Plusieurs résultats convergent avec ceux de Zhao et al. (2019). Le RW présente des p-valeurs s-SPA proches de zéro pour l'ensemble des facteurs, ce qui confirme qu'il est dominé par au moins un modèle concurrent. Par ailleurs, le DMA appartient au MCS pour quatre facteurs sur cinq, à savoir MKT, HML, RMW et CMA, avec une p-valeur de 1.0, ce qui est cohérent avec la conclusion du papier selon laquelle le DMA est le seul modèle appartenant à l'ensemble des meilleurs modèles.

Deux divergences notables méritent d'être soulignées. D'une part, le meilleur prédicteur individuel présente des p-valeurs s-SPA de 1.0 pour l'ensemble des facteurs, alors que le papier lui attribue des p-valeurs proches de zéro. Ce résultat s'explique par le fait que nos meilleurs prédicteurs individuels, notamment PSN et GP, surpassent le DMA sur certains facteurs en raison de l'absence d'*expanding window*, ce qui les rend impossibles à rejeter par le test s-SPA. D'autre part, le facteur SMB constitue un cas problématique : le DMA y obtient une p-valeur s-SPA de 0.0 et une p-valeur MCS de 0.0008, ce qui signifie qu'il est éliminé du MCS pour ce facteur, alors que le papier lui attribue systématiquement une p-valeur de 1.0. Cette divergence confirme et prolonge l'observation déjà faite au Tableau 7 : notre DMA ne domine pas le facteur SMB.

En définitive, la structure des résultats est correcte et partiellement cohérente avec Zhao et al. (2019). Le RW est systématiquement rejeté et le DMA appartient au MCS pour quatre facteurs sur cinq. Les divergences observées découlent des mêmes limites documentées tout au long de ce travail, à savoir un meilleur prédicteur individuel trop performant en raison de l'absence d'*expanding window* et un DMA insuffisamment dominant en raison du nombre limité de composantes PCA disponibles.

7 Performances des portefeuilles

7.1 Métriques de performance

Les performances hors-échantillon des différentes stratégies de portefeuille sont évaluées à l'aide de plusieurs métriques classiques de gestion quantitative permettant de mesurer simultanément le rendement, le risque global, le risque extrême ainsi que les bénéfices de diversification.

Le rendement annualisé mesure la performance moyenne du portefeuille sur une base annuelle :

$$R_{\text{ann}} = 12 \times \bar{r} \quad (59)$$

où $\bar{r}$ représente le rendement mensuel moyen du portefeuille.

Dans le cadre moyenne-variance, la performance ajustée du risque est mesurée par le ratio de Sharpe :

$$\text{Sharpe} = \frac{\mathbb{E}[R_p - R_f]}{\sigma_p} \quad (60)$$

où $\mathbb{E}[R_p - R_f]$ désigne le rendement excédentaire moyen du portefeuille et σ_p sa volatilité.

Le ratio de Sortino constitue une alternative au ratio de Sharpe en ne pénalisant que la volatilité baissière :

$$\text{Sortino} = \frac{\mathbb{E}[R_p - R_f]}{\sigma_d} \quad (61)$$

où σ_d représente l'écart-type des rendements négatifs.

Dans le cadre moyenne-CVaR, la performance ajustée du risque extrême est mesurée par le ratio Return/CVaR :

$$\text{Return/CVaR} = \frac{\mathbb{E}[R_p]}{\text{CVaR}_\alpha} \quad (62)$$

où CVaR_α correspond à la perte moyenne conditionnelle au-delà du quantile de risque α .

Le Maximum Drawdown (MDD) mesure la perte maximale observée entre un sommet et un creux de performance cumulée :

$$\text{MDD} = \max_{t \in [0, T]} \left(\frac{\max_{s \leq t} V_s - V_t}{\max_{s \leq t} V_s} \right) \quad (63)$$

où V_t désigne la valeur cumulée du portefeuille.

Enfin, le Conditional Diversification Benefit (CDB), mesure le bénéfice de diversification relativement aux bornes théoriques de risque extrême :

$$\text{CDB} = \frac{\overline{\text{CVaR}} - \text{CVaR}_{\text{port}}}{\overline{\text{CVaR}} - \underline{\text{CVaR}}} \quad (64)$$

où

$$\overline{\text{CVaR}} = \sum_i w_i \text{CVaR}_i \quad (65)$$

correspond à la moyenne pondérée des CVaR individuelles des actifs, et

$$\underline{\text{CVaR}} = -F_{\text{port}}^{-1}(q) \quad (66)$$

désigne la borne inférieure théorique du risque extrême.

Ces métriques permettent d'évaluer différentes dimensions de la qualité des stratégies d'investissement. Le rendement annualisé mesure la performance globale du portefeuille, tandis que les ratios de Sharpe, Sortino et Return/CVaR évaluent les performances ajustées du risque selon différentes mesures de risque. Le MDD renseigne sur les pertes extrêmes observées au cours de la période d'investissement. Enfin, le CDB permet d'évaluer l'efficacité de la diversification entre les facteurs de risque.

7.2 Facteurs individuels et portefeuille 1/N (Tables 8 & 9, Panel A)

Table 10: Performances des facteurs individuels et du portefeuille 1/N sur la période OOS 2000–2026 pour l'optimisation Mean-Variance (Table 8, Panel A)

Facteur	Rend. ann. (%)	Sharpe	Sortino	MDD (%)	CDB
MKT	4.852	0.319	0.432	54.108	—
SMB	4.359	0.402	0.626	22.657	—
HML	4.176	0.383	0.602	28.318	—
RMW	5.223	0.483	0.591	23.266	—
CMA	4.186	0.601	1.352	14.675	—
1/N	4.559	0.937	1.419	15.084	0.935

Table 11: Performances des facteurs individuels et du portefeuille 1/N sur la période OOS 2000–2026 pour l'optimisation Mean-CVaR (Table 9, Panel A)

Facteur	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
MKT	3.680	0.349	0.308	54.108	—
SMB	3.772	0.640	0.511	22.657	—
HML	3.583	0.529	0.495	28.318	—
RMW	4.625	0.650	0.484	23.266	—
CMA	3.942	1.265	1.249	14.675	—
1/N	3.920	1.344	1.153	16.016	0.926

7.3 Stratégies Mean–95% CVaR avec et sans vente à découvert (Table 9, Panels B & C)

Table 12: Performances des différentes stratégies de portefeuille (mean–CVaR)

Panel B : Mean–95%CVaR sans vente à découvert					
Modèle	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
RW-DCC-SKT	3.357	0.760	0.660	20.297	0.631
RW-ADCC-SKT	4.214	1.002	0.829	19.166	0.703
RW-GAS-SKT	3.702	0.873	0.744	21.280	0.688
Average	3.758	0.878	0.744	20.248	0.674
SC-SVR-DCC-SKT	3.631	0.523	0.465	33.564	-10.541
SC-SVR-ADCC-SKT	3.654	0.529	0.467	34.804	-8.846
SC-SVR-GAS-SKT	3.664	0.493	0.440	39.392	-
Average	3.650	0.515	0.457	35.920	-9.694
DMA-DCC-SKT	2.262	0.528	0.478	17.877	0.827
DMA-ADCC-SKT	2.428	0.559	0.504	17.811	0.820
DMA-GAS-SKT	2.570	0.606	0.544	17.789	0.822
Average	2.420	0.564	0.509	17.826	0.823
Total Average	3.276	0.653	0.570	24.665	-1.862
DCC Average	3.083	0.604	0.534	23.913	-3.028
ADCC Average	3.432	0.697	0.600	23.927	-2.441
GAS Average	3.312	0.657	0.576	26.154	0.755
Panel C : Mean–CVaR avec vente à découvert					
Modèle	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
RW-DCC-SKT-S	4.490	0.807	0.707	24.628	0.628
RW-ADCC-SKT-S	3.953	0.689	0.598	23.293	0.426
RW-GAS-SKT-S	4.002	0.760	0.676	22.887	0.548
Average	4.148	0.752	0.660	23.603	0.534
SC-SVR-DCC-SKT-S	3.318	0.526	0.435	26.098	-
SC-SVR-ADCC-SKT-S	3.593	0.585	0.488	25.902	-
SC-SVR-GAS-SKT-S	3.992	0.620	0.510	27.357	-2.958
Average	3.634	0.577	0.477	26.452	-2.958
DMA-DCC-SKT-S	3.192	0.627	0.558	26.647	0.807
DMA-ADCC-SKT-S	3.011	0.558	0.500	27.545	0.760
DMA-GAS-SKT-S	3.298	0.650	0.574	27.869	0.833
Average	3.167	0.612	0.544	27.354	0.800
Total Average - S	3.650	0.647	0.561	25.803	0.149
DCC-S Average	3.666	0.654	0.567	25.791	0.717
ADCC-S Average	3.519	0.611	0.529	25.580	0.593
GAS-S Average	3.764	0.677	0.586	26.038	-0.526

Les résultats de la Table 10 confirment seulement partiellement les conclusions de Zhao et al. (2019). Alors que les auteurs mettent en évidence une supériorité des stratégies fondées sur DMA et sur la structure de dépendance GAS, nos résultats montrent que les portefeuilles construits à partir des prévisions RW obtiennent généralement les meilleures performances en termes de rendement annualisé et de ratios ajustés du risque. Les stratégies DMA conservent toutefois les Maximum Drawdowns les plus faibles, ce qui traduit un profil plus défensif. Concernant les modèles de dépendance, GAS demeure globalement compétitif mais ne domine pas systématiquement les modèles DCC et ADCC. L'introduction de la vente à découvert améliore légèrement les performances globales sans modifier la hiérarchie observée entre les différentes approches. Dans l'ensemble, nos résultats suggèrent que les gains apportés par les méthodes les plus sophistiquées apparaissent plus limités sur la période étendue 2000–2026 que dans l'échantillon étudié dans le papier original.

7.4 Stratégies Mean–99% CVaR avec et sans vente à découvert (Table 9, Panels B & C)

Table 13: Performances des différentes stratégies de portefeuille (Mean–99% CVaR)

Panel B : Mean–99% CVaR sans vente à découvert					
Modèle	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
RW-DCC-SKT	4.115	0.554	0.751	20.781	0.519
RW-ADCC-SKT	3.783	0.530	0.733	19.940	0.605
RW-GAS-SKT	3.906	0.566	0.785	22.250	0.644
Average	3.934	0.550	0.757	20.990	0.589
SC-SVR-DCC-SKT	3.701	0.349	0.479	34.779	-14.893
SC-SVR-ADCC-SKT	3.855	0.363	0.493	33.749	-8.061
SC-SVR-GAS-SKT	3.628	0.313	0.415	40.231	—
Average	3.728	0.342	0.462	36.253	-11.477
DMA-DCC-SKT	2.626	0.452	0.557	17.883	0.836
DMA-ADCC-SKT	2.884	0.476	0.600	17.793	0.793
DMA-GAS-SKT	3.193	0.554	0.678	17.792	0.845
Average	2.901	0.494	0.612	17.823	0.825
Total Average	3.521	0.462	0.610	25.022	-2.339
DCC Average	3.481	0.452	0.596	24.481	-4.513
ADCC Average	3.507	0.456	0.609	23.827	-2.221
GAS Average	3.575	0.478	0.626	26.758	0.744
Panel C : Mean–99% CVaR avec vente à découvert					
Modèle	Rend. ann. (%)	Return/CVaR	Sortino	MDD (%)	CDB
RW-DCC-SKT-S	4.722	0.614	0.767	22.269	0.610
RW-ADCC-SKT-S	4.238	0.495	0.630	22.021	0.419
RW-GAS-SKT-S	5.061	0.645	0.791	24.277	0.544
Average	4.674	0.585	0.729	22.856	0.524
SC-SVR-DCC-SKT-S	3.636	0.307	0.453	24.621	—
SC-SVR-ADCC-SKT-S	3.040	0.244	0.366	30.763	—
SC-SVR-GAS-SKT-S	3.762	0.322	0.462	31.277	-2.119
Average	3.479	0.291	0.427	28.887	-2.119
DMA-DCC-SKT-S	3.474	0.469	0.607	26.228	0.760
DMA-ADCC-SKT-S	3.823	0.540	0.667	25.991	0.784
DMA-GAS-SKT-S	3.914	0.535	0.676	27.677	0.812
Average	3.737	0.515	0.650	26.632	0.785
Total Average - S	3.963	0.463	0.602	26.125	0.259
DCC-S Average	3.944	0.463	0.609	24.373	0.685
ADCC-S Average	3.701	0.427	0.554	26.258	0.601
GAS-S Average	4.246	0.501	0.643	27.743	-0.254

Les résultats de la Table 11 confirment les conclusions obtenues pour l'optimisation Mean–95% CVaR. Les stratégies fondées sur les prévisions RW demeurent les plus performantes en termes de rendement annualisé et de ratios ajustés du risque, tandis que les approches DMA conservent les Maximum Drawdowns les plus faibles. Contrairement aux résultats de Zhao et al. (2019), nous ne retrouvons pas de supériorité systématique des stratégies DMA ni du modèle de dépendance GAS. Bien que GAS obtienne certaines des meilleures performances individuelles, les écarts observés avec DCC et ADCC restent relativement limités. L'introduction de la vente à découvert améliore légèrement les rendements moyens des portefeuilles, sans toutefois modifier la hiérarchie entre les différentes méthodes.

8 Conclusion

Ce travail a conduit à la réplication de la méthodologie proposée par Zhao et al. (2019), combinant prévision des rendements factoriels, modélisation de la dépendance dynamique et optimisation de portefeuille, sur les cinq facteurs de Fama–French sur la période 1965–2026. Les résultats obtenus valident les grandes conclusions du papier original sur plusieurs dimensions. Sur le plan des prévisions, le DMA surpasse significativement le benchmark de marche aléatoire sur quatre facteurs sur cinq selon le test de Diebold–Mariano, et appartient au Model Confidence Set pour quatre facteurs sur cinq, conformément aux conclusions du papier. Sur le plan de la dépendance dynamique, le modèle GAS reproduit fidèlement la structure de corrélation de référence, avec dix signes corrects sur dix et une corrélation de rang de 0.993 avec le panel de Zhao et al. Sur le plan des portefeuilles, la vente à découvert améliore les performances et les stratégies DMA présentent systématiquement les drawdowns les plus faibles, reflétant un profil défensif cohérent avec les conclusions du papier. Plusieurs divergences quantitatives ont néanmoins été observées. Contrairement au papier, les portefeuilles fondés sur les prévisions RW dominent en termes de rendement annualisé et de ratios ajustés du risque sur la période étendue 2000–2026, et la supériorité de DMA sur l'ensemble des modèles de prévision n'est pas systématiquement retrouvée. Ces divergences s'expliquent principalement par des choix d'implémentation rendus nécessaires par des ambiguïtés méthodologiques dans le papier original, notamment l'estimation des modèles AR et ARMA par paramètres fixes en lieu et place d'une *expanding window*, ainsi que par des contraintes computationnelles.

En définitive, ce travail confirme la pertinence du cadre intégré de Zhao et al. tout en soulignant que les gains des méthodes les plus sophistiquées apparaissent plus limités sur une période étendue, ce qui invite à nuancer les conclusions du papier original quant à la supériorité systématique des approches bayésiennes dans un contexte de gestion factorielle à long terme.